

分类号 S757.2
密 级 GK



学位代码 309
学校代码 10298
学 号 3090623

南 京 林 业 大 学

研 究 生 硕 士 学 位 论 文

论文题目：基于独立成分分析的遥感影像变化检测

作 者：孙 青

专 业：森林经理学

研究方向：遥感与地理信息系统

指导老师：彭世揆 教 授

二〇一二年六月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下进行的研究工作所取得的成果。尽我所知，除文中已经特别注明引用的内容和致谢的地方外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式注明并表示感谢。本人完全意识到本声明的法律结果由本人承担。

学位论文作者（本人签名）：孙青

2012 年 6 月 13 日

学位论文出版授权书

本人及导师完全同意《中国博士学位论文全文数据库出版章程》、《中国优秀硕士学位论文全文数据库出版章程》（以下简称“章程”，见 www.cnki.net），愿意将本人的学位论文提交“中国学术期刊（光盘版）电子杂志社”在《中国博士学位论文全文数据库》、《中国优秀硕士学位论文全文数据库》中全文发表和以电子、网络形式公开出版，并同意编入 CNKI《中国知识资源总库》，在《中国博硕士学位论文评价数据库》中使用和在互联网上传播，同意按“章程”规定享受相关权益。

论文密级：

☒ 公开 ☐ 保密（___ 年 ___ 月至 ___ 年 ___ 月）（保密的学位论文在解密后应遵守此协议）

作者签名：孙青

导师签名：刘世楷

2012 年 6 月 13 日

2012 年 6 月 13 日

致 谢

一转眼，三年的硕士学习生涯即将结束，在这三年的学习生活里，有很多同学和老师给了我很多的关心和帮助，使我的生活变得丰富多彩。

首先，我要感谢我的导师彭世揆教授，从论文的选题、论文大纲的确定到具体论文的撰写，都离不开导师彭世揆教授的悉心指导和细心帮助。彭老师不仅学术渊博，治学态度严谨，而且具有高尚的生活情操和人格魅力，在生活上，彭老师常常教导我们如何做人，做事，做学问，这些都给我留下了深刻的印象，使我受益无穷。值此论文完成之际，谨向彭老师表示衷心的感谢！

其次，在研究生学习和论文完成过程中还得到教研组佘光辉老师、徐雁南老师、周春国老师、李明诗老师、温小荣老师、林国忠老师等众位老师的指导学习及各方面的建议。在此表示衷心的感谢！

还有，我要感谢唐晓燕、徐达、王妮、李杨、薛春燕、李伟、戎慧、张则飞、霍政权等师兄师姐们在学习和研究上的热心帮助和关心。感谢毛丽君、葛晶晶、王琨、顾胜男、刘敏、边疆、孙序磊、鲜明睿、薛冬冬等同学，以及实验室各位师弟师妹对我的真诚帮助和关心，使我的研究生生活绚烂美好，给我留下美好的回忆，在此对他们表示衷心的感谢！

最后，我要感谢我的父母、家人和朋友，在我多年的求学生涯中给予我无私的帮助和默默的支持鼓励，才能使我顺利完成学业。

衷心地感谢所有支持、关心和帮助过我的人！

作者：孙 青

二〇一二年六月

摘 要

多时相遥感图像变化检测是通过分析同一地区不同时间得到的遥感图像,定量分析和确定地物变化特征和过程的技术,用于资源和环境监测、自然灾害评估以及战场态势分析等。随着遥感技术的发展,变化检测已经成为当前遥感图像应用研究的一个重要方向。

PCA 是基于二阶统计的方法,只有在信号的统计分布符合高斯情况时,才能完全消除信号间的相关信息,而对于非高斯信号则只能去除信号间的二阶相关信息。但在多时相遥感图像中,各种地物的光谱特性并不都满足高斯分布,因此经过 PCA 变换的各成分图像间仍然存在高阶相关信息,而这些相关信息会影响到变化信息的检测。独立成分分析(ICA)作为近年出现的盲源分离技术,能够有效地消除多源信号间的二阶和高阶相关,经其变换的各分量之间相互独立。本文根据独立成分分析和不同时期遥感图像的特点,运用独立成分分析模型实现遥感影像变化检测。由于前、后时相的原始遥感影像包含多个波段,所以本文采用两种独立成分分析的方法对多时相遥感图像进行变化检测。

一是基于主成分分析的独立成分变换,此方法是将前后两时相的遥感图像进行主成分变换,使多波段图像信息集中到前两个主成分上,两时相主成分包含的信息量都达到了90%以上。然后对两时相主成分进行独立成分分析,实现变化检测。

二是基于多波段的独立成分变换。此方法是通过对两时相遥感图像的波段光谱特征、信息熵、相关系数等进行分析,选出最优波段组合,通过实验研究,本文选择波段4、5、7三波段作为实验波段组合,然后对两时相影像的三个波段组合进行独立成分变换,得到变化区域信息。

最后将本文提出的方法用于实验,并与常用的 PCA 方法进行了比较,实验结果显示第二种独立成分分析方法较好。

关键词: 遥感图像; 变化检测; 独立成分分析

Remote Sensing Images Change Detection Based on ICA

Abstract

Through change detection between multi-temporal remote sensing images of the same region, one can determine the change characters and process quantificationally for the remote sensing images obtained from different time. It is used for resources and environment monitoring, evaluation and natural disasters of battlefield analysis, etc. With development of remote sensing, change detection has become an important research direction of remote sensing images's application.

PCA is a method based on second-order statistics, only the statistics of the signal distribution, subject to the Gaussian case, to completely eliminate the signal information, and for non-Gaussian signal can only remove the signal between the second-order information. But in the multi-temporal remote sensing image, the spectral characteristics of various surface features do not satisfy the Gaussian distribution, so after PCA transform, the components of the image still exist between high order related information, and the related information will affect change information detection. Independence component Analysis (ICA) is a blind source separate technique appeared in recent years, It can reduce second and high-order dependences in observed data, and the independent components are statistically as independent as possible. In this paper, according to independent component analysis and different period of remote sensing image characteristics, use independent component analysis model realize remote sensing image change detection. Because the before and after phase's remote sensing images contains many wave bands, therefore this paper achieves the change detection based on multi-temporal remote sensing image by using two kinds of independent component analysis.

First, the independent component analysis based on principal component transform. This method is to carry on the principal components transformation to Around two phase remote sensing images, make the multi-band image information into the first two principal components, then carry on the independent component analysis to two phase principal components, to achieve change detection.

Second, the independent component analysis based on multi-wave band image. This method is to select the most superior wave band combination through the analysis band spectral features, information entropy, correlation coefficient of the two phase remote sensing image. After the experimental study, select the band 4, 5, 7 as an experimental band combination, and then use the three band combination of the phase two images do independent component transformation, to get change information area.

Finally, use these two methods in the experiment, and compared with PCA, the results show that the second independent component analysis method is better.

Keywords: Remote sensing image; change detection; independent component analysis

目 录

第一章 前 言	1
1.1 研究的目的与意义	1
1.2 独立成分分析的国内外研究现状	2
1.2.1 国外研究现状	2
1.2.2 国内研究现状	3
第二章 独立成分分析的基本理论	5
2.1 ICA 的基本概念	5
2.2 ICA 的假设和约束	5
2.3 数据预处理	6
2.4 ICA 模型的估计方法	6
2.4.1 极大化非高斯的 ICA 的估计方法	6
2.4.2 极小化互信息的估计	8
2.4.3 极大似然估计	9
2.4.4 基于张量的 ICA 估计方法	10
2.4.5 基于非线性 PCA 的 ICA 估计方法	10
第三章 研究区概况及研究资料	11
3.1 研究区概况	11
3.2 资料收集	11
3.3 研究技术路线	12
第四章 遥感图像的预处理	13
4.1 图像的校正	13
4.1.1 几何校正	13
4.1.2 辐射校正	14
4.2 TM 影像特征分析	15
4.2.1 TM 各谱段图像特性	15
4.2.2 最优波段选择	16
4.3 图像变换	18
4.3.1 主成分变换	18
4.3.2 缨帽变换	20
4.3.3 最小噪声分离	20
4.3.4 植被指数	20
4.3.5 水体指数	21
第五章 六种 ICA 算法在图像处理中的实验	22
5.1 六种 ICA 算法	22
5.2 六种 ICA 算法在图像处理中的实验	23
5.2.1 自然图像的独立成分分离实验	23

5.2.2 ICA 算法的分离性能指标	25
5.2.3 TM 图像的独立成分分离实验	26
第六章 独立成分分析在多时相遥感图像变化检测中研究	30
6.1 多时相遥感变化检测的理论	30
6.2 基于独立成分分析的多时相遥感图像变化检测	32
6.3 变化检测分析	33
6.3.1 变化检测结果图	33
6.3.2 变化信息的提取	35
6.3.3 变化类型的确定	38
6.3.4 变化检测结果的评价	39
第七章 结 论	42
7.1 结论	42
7.2 不足之处	43
参考文献	44
附图	48

第一章 前言

1.1 研究的目的与意义

遥感是通过不与物体、区域或现象接触获取调查数据，并对数据进行分析得到物体、区域或现象有关信息的一门科学技术^[1]。变化检测是通过分析同一地区不同时相的遥感图像，检测出该地区中地物随时间发生变化的信息。随着遥感和信息技术的发展，变化检测已经成为当前遥感图像分析研究的一个重要方向，广泛地应用于许多领域，如资源保护中森林覆盖的动态监测、城市规划中土地利用与覆盖的变化信息获取、军事侦察中战略目标的动态监视以及自然灾害评估等^[2]。

遥感图像的变化检测是对在特定波段上不同时间（或者日期）获取的多时相图像检测和辨识成像日期之间的地物的动态发展变化^[1]。早期的遥感影像变化检测由于受到当时技术条件的限制，变化检测手段主要是采取人工目视解译来进行的，而目视解译方法要求解译人员具有丰富的目视判读经验，并且工作量大，效率低下，最后得到的结果在很大程度上受到主观因素影响，容易产生错误，难以保证前后一致性，所以其在实际应用中具有很大的局限性^[3]。

随着技术的发展，目前出现了很多应用于不同环境的变化检测方法^[4]，根据实现的途径主要可以分为 3 类^[5]：（1）基于简单代数运算，如图像差分、图像比值和图像回归分析。这类方法都是通过对多时相遥感图像进行代数运算，根据辐射值的差异检测出变化的区域^[6]。（2）基于图像分类，如分类后比较。这类方法首先对多时相遥感图像进行分类，然后根据分类后的地物类别进行变化检测。（3）基于多变量分析的数据变换方法，如 PCA，MAD 和 Canonical 分析。PCA 变换是变化检测中应用最广泛的一种方法。它是基于二阶统计的方法，只有在源信号的统计分布符合高斯分布时，才能完全消除信号间的相关性，而对于非高斯信号则只能去除信号间的二阶相关性。但在多时相遥感图像中，各种地物的光谱特性并不都满足高斯分布，因此经过 PCA 变换得到的各成分图像之间仍然存在高阶相关性，而这些相关信息会影响到变化信息的检测结果。独立成分分析（ICA）是近年出现的盲源信号分离技术，它不仅能够有效的消除信号间的二阶和高阶相关，而且使经其变换的各分量之间相互独立。ICA 利用了观测数据的高阶统计信息，能有效的对观测信号进行分解，同时，也可以大大降低数据的维数，使后续聚类的规模不至于庞大，所以将 ICA 应用于多光谱数据的分解，它能有效的利用数据的高阶统计信息，去除数据间的相关性，更好地利用多光谱数据的光谱信息，从而提高分类精度。本文根据独立成分分析和不同时期遥感图像的特点，运用独立成分分析模型实现多时相遥感影像的变化检测，以提高变化检测精度。

1.2 独立成分分析的国内外研究现状

1.2.1 国外研究现状

20 世纪 50 年代早期, 法国学者 Herault、Jutten 和 Ans^[7~9]在神经生物学的背景下, 提出了一个特别的反馈电路 (Feed back Circuit), 用于解决肌肉收缩运动编码的简化模型, 从而引入了 ICA 技术。1986 年, Herault 和 Jutten^[10]在美国举行的神经网络计算会议上, 进一步提出了一种反馈神经网络模型和一种基于 Hebb 学习规则的学习算法, 实现了两个独立源信号的盲分离。1991 年, 发表于 Signal Processing 杂志的三篇经典文章, 标志着盲源分离研究的重大进展。1994 年, Comon^[11]从数学角度给出了 ICA 的统一框架, 界定了 ICA 方法的基本假设条件, 明确指出了对比函数 (Contrast Function) 的目标函数达到极大值来消除观测信号中的高阶统计关联, 从而实现盲源分离。

1995 年, Bell 和 Sejnowski 基于信息极大化原理, 发表了 ICA 发展史上的里程碑文章^{[12][13]}。其重要贡献在于: 1) 利用神经网络的非线性特性来消除观测信号中的高阶统计相关性。2) 用信息极大化准则建立目标函数, 从而将信息论方法与 ICA 结合起来。3) 给出了神经网络式的最优迭代学习算法 (简记为: Infomax 算法或者 B-S 算法), 成为后续各种算法的基础。4) 对具有 10 个说话人的鸡尾酒会问题给出了很好的分离效果。日本学者 Amari 等人^{[14][15]}从参数空间的黎曼几何结构出发, 给出了改进的 Infomax 算法, 该方法基于自然梯度方法, 克服了原始 Infomax 算法需要计算逆矩阵、收敛速度较慢的问题。同期, 法国学者 Cardoso 等人^{[16][17]}从 ICA 问题的李群结构出发, 基于等变化性, 提出了类似于自然梯度型算法的相对梯度型算法, 就学习算法的等变化性、稳定性和分离精度等问题给出了重要的思路和方法。与最初的 Infomax 算法相比, 自然梯度型算法和相对梯度型算法避免了矩阵逆的计算, 提高了算法的计算效率。1996 年, Peadmutter 等^{[18][19]}通过多变量概率密度函数的定义和在线参数估计方法, 进一步推广了最初的 Infomax 算法, 得到了极大似然估计算法, 从而扩大了可分离的源信号类型的范围。基于极大似然目标函数, 涌现出了众多的学习算法, 比如极大似然的自然梯度法、相对梯度法等^{[16][19][20]}, 并且 Cardoso 指出极大似然估计和信息极大原理是等价的。同样地, 为了克服原始的 Infomax 算法只能解决超高斯信号混合的盲源分离问题这一缺陷, Girolami、Lee 和 Sejnowski^{[21][22]}等学者将基于信息极大化的 ICA 作了进一步的扩展, 通过稳定性分析来设置开关函数以选择不同的非线性函数来分别实现超高斯信号和亚高斯信号的盲源分离, 这就是著名的扩展信息极大化算法 (ExtICA 算法)。

以上 ICA 学习算法均是梯度上升或梯度下降方法, 这类方法收敛速度较慢, 尤其是在进行规模较大的数据处理时, 计算的时间较长, 效率低, 并且需要针对不同的问题来选取合适的选取学习率。对此, Hyvarinen 和 Oja 等学者基于负熵极大化准则, 提出了 ICA 的不动点算法 (FastICA 算法或 Fixed-Point 算法)^[23~26]。这种 ICA 算法的优点是收敛速度快, 不需要用户选择学习率 (学习步长)。由于该算法的优异性能, 在实际计算中被广泛应用。目前, 在国际上广泛使用的是 FastICA 算法和 Lee^[27]等的扩展的 Infomax 算法 (ExtICA)。Shi 等综合了 FastICA 算法和 ExtICA 算法两者的优势, 提出了一个新的不动点算法, 能够

自动的分离具有超高斯和亚高斯分布源的混合信号，并且算法具有收敛速度较快、分离精度更高、不需要设定学习步长等优势。2000 年，Lee 等学者基于互信息极小化方法，提出了梯度学习算法。Hyvarinen^[26]和 Lee^[27]等学者还证明了基于极大似然估计方法、负熵极大化方法以及互信息极小化方法的学习算法与基于信息极大化得到的学习算法是等价的。Cardoso 较早的用四阶矩进行盲源分离（Fourth-Order Blind Identification, FOBI），提出了一种简单的正交和加权两步代数算法，使用该算法，独立源信号可以较容易的作为改进了的协方差矩阵的特征矢量被辨识出来，但该算法不能辨识出具有相同分布的源信号。针对这一缺点，Tong 和 Liu 等^[28]首先通过正交变换，然后对观测信号的四阶矩进行奇异值分解，得到了扩展的四阶盲辨识（Extended FOBI, EFOBI）和多未知信号抽取算法（Algorithm for Multiple Unknown Signals Extraction, AMUSE）。Cardoso^[29]还提出了用联合近似对角化（Joint Approximate Diagonalisation of Eigenmatrices, JADE）四阶累积量的特征矩阵进行盲提取的方法，通过联合对角化累积量矩阵，使得处理所有累积量集合的计算效率与基于特征值分解的技术相当。由 H-J 算法出发，Cichocki 及其合作者们发展了 Cichocki-Unbenauen 算法^[30~32]，它是一个性能和可靠性更好的算法。Oja、Xu 和 Karhunen 等人最早在 PCA^{[33][34]}方法中引入某种非线性性，提出了非线性 PCA 的概念，并将其应用于盲信号分离中。但最早提出的非线性 PCA 方法只适用于亚高斯信号。因此，1997 年 Girolami 和 Fyfe^[35]将其发展到亚高斯和超高斯两类源信号混合的分离问题，此方法可以看作是 Comon 批处理优化算法^[29]的自适应推广。

1.2.2 国内研究现状

1994 年，胡波和凌燮亭^[36]结合传感器阵列接收信号的微分信号，利用自学习盲信号分离方法实现了延时窄带信号的盲分离，并利用反馈式神经网络根据 Hebbian 的学习算法，实现了近场情况下一般信号的盲分离。利用天线阵列，接收信号可以看作是由 N 个独立信号源激励的线性传输混合系统的输出，由于信道存在码间干扰，混合矩阵的元素不是常数，而是一个线性子系统，针对这一情况，凌燮亭^[37]于 1995 年提出了一个新的盲分离器结构，首先将接收信号进行盲分离，然后利用基于模型的盲均衡器消除每一路输出信号的码间干扰，从而实现了多用户信号的分离。张贤达^[38]在 1996 年出版的《时间序列分析—高阶统计量方法》一书中，系统的介绍了有关盲分离的基本理论，并给出了相关的算法。2002 年张贤达、朱孝龙和保铮^[39]提出了分阶段选择盲分离算法学习率的方法。2004 年，张贤达、朱孝龙等提出了基于自然梯度的递归最小二乘盲信号分离算法，并对音频信号的盲分离与半盲分离进行了相关的研究。1996 年，汪军和何振亚^[40]讨论了一般情况下的宽带盲辨识和信号盲分离问题。1998 年，何振亚等^[41]证明了 Linsker 的 Infomax 算法在输入-输出为非线性映射且无输入噪声条件下与 ICA 算法等价，而当输入-输出为线性映射且输入信号和噪声为高斯分布条件下 Infomax 算法与 PCA 算法等价。1998 年，刘据等^[42]给出了一种新的基于信息理论的盲信号分离判据，该判据基于统计独立的假设，同时利用了最大信息传输和输出互信息最小化。刘据等^[43]给出一种瞬时混迭信号分离的自适应方法，该方法将预白化和正交化合二为一。1999 年，刘据等根据统计独立的假设，利用概率密度函数的 Edgeworth 展开，提出了一种基于互信息最小化准则的分离方法，同时对盲反卷积和盲信

道均衡的算法做了研究。2001 年,刘据等给出一种新的盲源信号分离准则,该算法既可以分离超高斯源的混和信号,又可以分离亚高斯源的混和信号。近几年,刘据等提出了基于 ICA 的数字水印方法以及基于 ICA 的无线通信空时信号处理技术,媒体通信与网络传输技术等。1999 年,冯大政、史维祥提出了一种具有抑制噪声作用的有效自适应学习算法,研究了算法的有界性和渐进稳定性^[44]。另外,冯大政等^[45]提出了一些新的信号盲分离算法,算法的每个阶段仅抽取单个独立成分。同时他们对高维数据流的自适应的特征抽取问题进行了研究。对于递归最小二乘问题,冯大政等人近几年也做了较深入的研究。2000 年胡光锐、虞晓等^[46]研究了盲信号处理在语言分离和识别领域的应用,在分析最大熵方法与最小互信息方法的基础上,提出了一种利用反馈结构的输出信号概率密度函数估计的增强最大熵算法。张丽清等利用非线性激励函数自适应学习来实现盲分离。吴小培^[47]提出了用 ICA 进行生物医学信号中工频干扰消除的新方法。将 ICA 用于脑电信号的预处理中,分离出脑电信号中的心电干扰。并在图像处理、语音信号等方面做了应用。李全政等人^[48]基于 ICA 方法基本上解决了 TEB 中呼吸干扰的去除问题。洪波等^[49]提出了一种扩展的 ICA 算法的视觉诱发响应少次提取与波形分析方法。王刚和胡德文研究了 FastICA 的伪平衡解的存在性问题。此外,黄德双等人就 ICA 在生物医学数据处理中的应用做了较深入的探讨。

第二章 独立成分分析的基本理论

2.1 ICA 的基本概念

独立成分分析(ICA)是将数据变换到相互独立的方向上,使经过变换所得到的各个分量之间不仅正交,而且相互独立。它最初是用来解决“鸡尾酒会”问题(即从酒会的嘈杂人声中提取所关心对象的语音)，“鸡尾酒会”问题是一种经典的盲信号分离(BSS)问题。盲源分离是在没有其它先验知识的情况下,根据源信号的统计特性,仅由观测的混合信号分离出未知的源信号的过程。而独立成分分析(ICA)就是为解决盲源分离问题发展起来的一项信号处理技术,也是信号处理领域的一个研究热点。

ICA 的目的是把混合信号分离为相互独立的分量,它强调分解出来的各分量相互独立。主成分分析(PCA)是基于信号二阶统计特性的分析方法,其目的用于去除图像各分量之间的相关性,主要应用于图像数据的压缩;而 ICA 是基于信号高阶统计特性的分析方法,经 ICA 分解出的各信号分量之间是相互独立的。正是因为这一特点,ICA 被广泛应用于语音信号处理、图像处理、生物医学信号处理、模式识别、通信等研究领域。

ICA 的基本模型: 假设有 n 个统计独立的源信号 s_1, s_2, \dots, s_n 和 m 个观测信号 x_1, x_2, \dots, x_m , 观测信号 X 和未知的源信号 S 之间的关系如下:

$$x_i = a_{i1}s_1 + a_{i2}s_2 + \dots + a_{in}s_n, i = 1, 2, \dots, m \quad (2-1)$$

矩阵形式为

$$X = AS \quad (2-2)$$

其中 X 为 m 维的观测信号向量, A 为未知的 $m \times n$ 的混合矩阵, S 为未知 n 维的独立源信号向量。ICA 的目的就是通过观测数据 X 来估计未知的源信号 S 或是估计混合矩阵 A , 即求解一个解混矩阵 W , 使得 $Y = WS$ 的各分量尽可能相互独立, 并把 Y 作为源信号 S 的估计。

2.2 ICA 的假设和约束

由于源信号和混合矩阵 A 的先验知识未知, 仅由 X 估计出 S , 一定有多解, 所以必须做出一定的假设和约束。

(1) 假定源信号的分量是统计独立的

该假设是 ICA 能够成立的基本要求。ICA 模型能够被估计, 仅仅这个约束就基本足够了, 这就是 ICA 能在许多不同领域的应用中成为一个强有力的方法的原因。

(2) 源信号必须具有非高斯的分布, 最多只有一个观测变量是高斯分布。

由于多个高斯信号的线性混合仍为高斯信号, 而 ICA 不可能对高斯信号进行分离; 但源信号中只有一个观测变量是高斯分布的, ICA 是可以解决的。

(3) 假设未知的混合矩阵 A 是方阵, 而且是可逆的。

这就要求独立成分的个数与观测到混合量的个数相同。如果得到矩阵 A 的估计, 就可

以计算其逆矩阵 B ，通过公式 $S = BX$ 得到其独立成分。当然，混合量的个数与独立成分的个数也有不相等的时候，对此，许多学者也提出很多算法^{[50][51]}。

由于源信号 S 和混合矩阵 A 都是未知的，所以求得的 ICA 模型的解不是唯一的，其中存在一些必然的含混因素或者不确定：一是无法确定独立成分的方差（能量）；二是无法确定独立成分的次序。

2.3 数据预处理

由于在实际应用中，要处理的数据是复杂而繁多的，特别是数据量较大的遥感图像，计算就会变得困难复杂。所以为了简化算法，通常在求解 ICA 问题之前，需要对待处理的数据进行预处理。一般而言，ICA 算法进行预处理后收敛更快，能获得更好的稳定性。预处理过程包括两方面：中心化和白化。

(1) 中心化

中心化就是去除观测信号的均值，使得观测信号成为零均值变量，这意味着 ICA 得到的源信号的估计信号也是零均值的。通过中心化预处理后，混合矩阵仍然保持不变，因此中心化不影响混合矩阵的估计。在完成独立成分的估计后，可以在源信号的估计值加上先前去掉的均值即可。

(2) 白化

白化又称球面化，是指一个零均值的随机变量 y 的各分量具有相同的单位方差且互不相关，即 y 的协方差矩阵是单位阵：

$$E\{y^T y\} = I \quad (2-3)$$

白化方法基本上有两类：一类是利用混合信号的协方差矩阵的特征值分解实现的；另一类则是通过迭代算法对混合信号进行线性变换实现的^[52]。目前常使用的是第一类方法。

给定 n 维随机变量 x ，寻找线性变换 V ，使得变化后的向量 $z = Vx$ 是白的。

令 $E = (e_1, \dots, e_n)$ 以协方差矩阵 $C_x = E\{x^T x\}$ 的单位范数特征向量为列的矩阵。令 $D = \text{diag}(d_1, \dots, d_n)$ 是以 C_x 的特征值为对角元素的对角矩阵。则线性白化变换有由式(2-4)给出：

$$V = D^{-1/2} E^T \quad (2-4)$$

此时白化可通过白化矩阵 V 来实现。

白化仅仅是 ICA 方法的一部分，白化只是去除信号之间的相关性，最多只能给出在正交意义上独立成分的一个可能集合，但不足以实现信号的盲分离，因此可以说白化过程只解决了 ICA 问题的一半。

2.4 ICA 模型的估计方法

2.4.1 极大化非高斯的 ICA 的估计方法

非高斯是独立成分分析的最重要的特征。通过中心极限定理知，在一定条件下，独立的随机变量之和的分布趋向于高斯分布。或者不太严格地讲，两个独立随机变量之和形成的分布比两个原始的随机变量中的任意一个更接近于高斯分布。

假定源信号向量 X 是按照 ICA 数学模型形成其分布: $x = As$ 。即该向量是源信号向量的混合。对上述公式求逆并表示成一种线性求和的形式: $s = A^{-1}x$ 。因此, 为了估计出其中一个独立成分, 可以考虑对 x_i 进行某种线性组合。用 $y = b^T x = \sum_i b_i x_i$ 表示该组合, 其中 b 是待确定的向量。由此推出 $y = b^T As$, 故 y 是 s_i 的某种线性组合, 而系数由 $b^T A$ 给出。系数向量记为 q , 可以得到:

$$y = b^T x = q^T s = \sum_i q_i s_i \quad (2-5)$$

若 b 是 A 逆矩阵的其中的一行, 则 $b^T A$ 刚好是其中的一个独立成分, 而对应的向量 q 只有一个元素为 1, 其他元素均为 0。因此直接把向量 b 用于极大化 $b^T x$ 的非高斯性, 通过极大化 $b^T x$ 的非高斯性, 就能给出其中一个独立成分。

非高斯性在 ICA 模型的估计中扮演着极为重要的角色, 所以为了估计 ICA 模型, 需要找到度量随机变量非高斯性的指标。一般来说, 度量非高斯性的指标有两种: 一是峭度(Kurtosis), 二是负熵(Negentropy)。

(1) 峭度

峭度是反映信号分布特性的数值统计量, 是归一化的四阶中心矩。其定义公式为:

$$kurt(y) = E\{y^4\} - 3(E\{y^2\})^2 \quad (2-6)$$

假定 y 已经被标准化过, 其方差等于 1: $E\{y^2\} = 1$ 。由此公式 (2-6) 的右边可简化为 $E\{y^4\} - 3$ 。这说明峭度就是四阶矩的一种规范化形式。非高斯性可由峭度的绝对值或者峭度的平方来度量。这样的度量对于高斯变量的取值为零, 对于大部分 (但并不是所有) 的非高斯随机变量的值大于零。也存在峭度值为零的非高斯变量, 但这样的变量非常少见。

峭度对应的 ICA 的优化算法, 首先对数据进行预处理, 得到预处理后的数据 z 。对 ICA 的估计通过寻找一个极大化非高斯性的线性组合 $w^T z$ 来实现, $w^T z$ 的峭度绝对值的梯度可以用式 (2-7) 计算得到^[26]:

$$\frac{\partial |kurt(w^T z)|}{\partial w} = 4 \text{sign}(kurt(w^T z)) [E\{z(w^T z)^3\} - 3w\|w\|^2] \quad (2-7)$$

由于 $E\{(w^T z)^2\} = \|w\|^2$ 且 $\|w\|^2 = 1$, 则梯度算法简化为:

$$\Delta w \propto \text{sign}(kurt(w^T z)) E\{z(w^T z)^3\} \quad (2-8)$$

$$w \leftarrow \frac{w}{\|w\|} \quad (2-9)$$

这就是基于峭度的 ICA 估计算法。

(2) 负熵

虽然用峭度量非高斯性比较简单, 但在实际应用中, 峭度可能对野值极其敏感, 因此它并不是非高斯性的一个鲁棒度量。而负熵是一个非高斯性度量稳定的方法, 但计算较为复杂。随机变量的熵与 (对该变量的) 观测能给出的信息有关, 变量越“随机” (指不可预测和无结构), 熵越大。密度函数为 $p_y(\eta)$ 的随机向量, 其定义^[53]为:

$$H(y) = -\int p_y \log p_y(\eta) d\eta \quad (2-10)$$

负熵 J 的定义:

$$J = H(y_{gauss}) - H(y) \quad (2-11)$$

其中 y_{gauss} 与 y 具有相同相关(和协方差)矩阵的高斯随机变量, 但负熵计算非常困难。所以在实际应用中一般使用负熵的近似。

负熵 J 的近似表达式为:

$$J(y) \propto [E\{G(y)\} - E\{G(v)\}]^2 \quad (2-12)$$

其中 v 是一个标准化的高斯变量, $G(\cdot)$ 可以是任意的非二次函数。此类函数随自变量增长不是很快, 这样能得到更为鲁棒的估计。下面的函数已被证实是非常有用的:

$$G(y) = \frac{1}{a_1} \log \cosh a_1 y \quad (2-13)$$

$$G(y) = -\exp(-\frac{y^2}{2}) \quad (2-14)$$

其中 a_1 为常数, 取在 $1 \leq a_1 \leq 2$ 范围内比较合适, 通常取 1。基于上述的近似函数, Hyvarinen 给出了著名的快速不动点算法 FastICA, 其不动点迭代公式为:

$$w \leftarrow E\{zg(w^T z)\} - E\{g'(w^T z)\} \quad (2-15)$$

$$w \leftarrow \frac{w}{\|w\|} \quad (2-16)$$

其中 $g(\cdot)$ 是 $G(\cdot)$ 函数的导数。

FastICA 算法在无需快速适应变化的情况下其特性明显比梯度算法优越。即使只用到负熵的一般形式的近似, 其收敛特性也是二次化的。更进一步, 由于算法没有学习率或者其他需要调整的参数, 故算法容易使用, 更加可靠。

2.4.2 极小化互信息的估计

互信息是随机变量之间依赖性的自然度量。它总是非负的, 当且仅当变量之间的统计独立时其互信息为零。互信息考虑了整个变量的依赖结构, 而不像主成分分析和相关方法仅考虑协方差。因此, 我们可以使用互信息作为寻找 ICA 表示的标准。

设 m 个随机变量 $y_i, i = 1, \dots, m$ 的互信息定义为:

$$I(y_1, y_2, \dots, y_m) = \sum_{i=1}^m H(y_i) - H(y) \quad (2-17)$$

$H(y_i), H(y)$ 分别为边缘熵和联合熵。当且仅当 y 的各分量统计独立的时候互信息 $I(y)$ 为零。即互信息越小, 各分量之间的独立性越强。基于最小互信息的目标函数为:

$$I(y_1, y_2, \dots, y_m) = H(y_i) - H(y) - \log|\det(W)| \quad (2-18)$$

当 y_i 不相关且为单位方差, 则 $E\{yy^T\} = WE\{xx^T\}W^T = I$, 于是得到:

$$\det I = 1 = \det(WE\{xx^T\}W^T) = \det(W)(\det E\{xx^T\})(\det(W^T)) \quad (2-19)$$

这说明 $\det(B)$ 必须是常量, 于是得到:

$$I(y_1, y_2, \dots, y_m) = \text{常量} - \sum_i J(y_i) \quad (2-20)$$

式中, 常量不依赖于 B 。这表明了负熵和互信息的关系。所以寻找极小化互信息的可逆线性变换 W 粗略地等价于使负熵极大化的方向。极小化互信息估计对应的优化算法为

MMI 算法。

2.4.3 极大似然估计

极大似然估计是估计 ICA 模型的一个很流行的方法。极大似然估计就是采纳那些使得所得观测量具有最大概率的估计参数值。

混合向量的概率密度： $x = As$ (2-21)

可以写成：

$$p_x(x) = |\det(B)| p_s(s) = |\det(B)| \prod_i p_i(s_i) \quad (2-22)$$

式中， $B = A^{-1}$ ， p_i 表示独立成分的概率密度。

式 (2-22) 还可以表示为矩阵 $B = [b_1, \dots, b_n]^T$ 和向量 x 的函数：

$$p_x(x) = |\det(B)| \prod_i p_i(b_i^T x) \quad (2-23)$$

假定我们有 x 的 T 个观测量，分别为 $x(1), x(2), \dots, x(T)$ ，似然度记为 L ，把它作为 B 的函数：

$$L(B) = \prod_{t=1}^T \prod_{i=1}^n p_i(b_i^T x(t)) |\det(B)| \quad (2-24)$$

使用对数对似然度进行简化为：

$$\log L(B) = \sum_{t=1}^T \sum_{i=1}^n \log p_i(b_i^T x(t)) + T \log |\det(B)| \quad (2-25)$$

$$\frac{1}{T} \log L(B) = E \left\{ \sum_i \log p_i(b_i^T x) \right\} + \log |\det(B)| \quad (2-26)$$

Bell-Sejnowski 算法：极大化似然度最简单的算法可通过梯度法得到。对数似然度的随机梯度：

$$\frac{1}{T} \frac{\partial \log L}{\partial B} = [B^T]^{-1} + E \{ g(Bx) x^T \} \quad (2-27)$$

这里 $g(y) = (g_1(y_1), \dots, g_n(y_n))$ 是一个逐元素的向量函数，它包含的函数 g_i 被称为分布 s_i 的（负）评分函数，定义为：

$$g_i = (\log p_i)' = \frac{p_i'}{p_i} \quad (2-28)$$

由此得到极大似然估计算法：

$$\Delta B \propto [B^T]^{-1} + E \{ g(Bx) x^T \} \quad (2-29)$$

其中非线性函数 g ，对于超高斯的独立成分，可采用 \tanh 函数： $g(y) = -2 \tanh(y)$ ，对于亚高斯的独立成分： $g(y) = \tanh(y) - y$ 或者 $g(y) = -y^3$ 。

极大似然度可通过简单的梯度法得到。似然度的极大化也可以通过不动点算法实现，FastICA 给出的不动点算法是一种非常快速可靠地极大化方法。

2.4.4 基于张量的 ICA 估计方法

用 ICA 来估计独立成分还可以使用高阶累积张量。张量是矩阵或线性算子的推广，而累积张量是协方差矩阵的推广。协方差矩阵是二阶累积张量，而四阶张量定义为四阶累积量 $cum(x_i, x_j, x_k, x_l)$ 。特征矩阵的联合对角化 (JADE)，是为了解决累积张量具有相同特征值问题的一种原理和方法。利用信号自身特征，根据高阶累积量将 BSS (盲源分离) 问题转化为特殊矩阵对角化问题，也称为特征值分解问题 (EVD)。J Cardoso 很早就提出了四阶盲辨识 (FOBI) 算法；后来他使用四阶累积量矩阵的联合对角化提出了 JADE 算法^[54]。

2.4.5 基于非线性 PCA 的 ICA 估计方法

一个非线性表示是寻找使最小二乘误差最小的输入数据，PCA 的一个基本定义是最小均方误差压缩。非线性 PCA 估计可以从常规的 PCA 算法的目标函数引入合适的非线性函数直接得到。非线性 PCA 的目标函数：

$$w_i = \arg \max_{\|w\|=1} E\{f(W^T X)^2\} \quad (2-30)$$

选取不同的目标函数可以得到不同的非线性 PCA 算法。一种较为简单的目标函数为：

$$J = \sum_{j=1}^n E\{f(y_i)\} \quad (2-31)$$

若 $f(y) = y^4$ ，则目标函数为：

$$J = \sum_{j=1}^n E\{y^4\} \quad (2-32)$$

为输出数据四阶矩之和，对分离矩阵 W 来说，亚高斯信号使上式取最小值，超高斯信号使上式取最大值。

第三章 研究区概况及研究资料

3.1 研究区概况

中山陵园风景区是钟山风景名胜区的重要组成部分，地处南京城区东隅，以宁杭公路为南界，东至环陵路，北到宁栖路，西迄太平门、玄武湖，与南京古城墙毗邻。地理坐标为东经 $118^{\circ}48'24'' \sim 118^{\circ}53'04''$ ，北纬 $32^{\circ}01'57'' \sim 32^{\circ}16'15''$ ，它东西长 7.1km，南北宽 6.7km，近似一个菱形，周长 24km，总面积 3008hm^2 。

中山陵风景区地处中纬度，属亚热带向暖温带过渡地带，具有北亚热带气候特征。由于森林起着调节气候的作用，使得中山陵风景区气温变化较小，水分亏缺也相对较低，特别有利于落叶阔叶林的生长。由于景区内的地理环境的影响及森林的气候调节作用，随着森林次生演替的发展，中山陵地区的森林环境为常绿植物生长创造了有利条件，利于植物引种，植物种类丰富。紫金山的顶部以石英砾岩构成山脊，不易风化；山的西北樱桃园、天堡城一带为火成岩中粒和粗粒组织，较易风化，形成坡积平地或不相连的山脊；东部和北部多为紫色页岩，风化后成页状碎粒；北坡为一断层，坡度大，页岩块小，易受冲刷；南坡主要由石英砂岩构成，不易风化，坡度较缓。紫金山的土壤在土类上属黄棕壤和黄褐土类，但是由于地形、母质和植被不同，所形成的土壤性状也不完全相同。图 3-1 显示了研究区范围的两期假彩色合成图（RGB432）。




图 3-1 研究区域两期假彩色合成图

3.2 资料收集

本文的研究区采用的卫星数据为 1998 年 4 月 27 日的 TM 数据和 2006 年 5 月 20 日的 TM 数据，分辨率为 30m。中山陵风景园林景区地形图，比例尺为 1:10000，1999 年制图。研究中使用的主要软件为 ARCGIS 9.3，ENVI 4.3，ERDASIMAGINE 9.2，MATLAB 7.8，Photoshop7.0。

3.3 研究技术路线

本文研究技术路线：

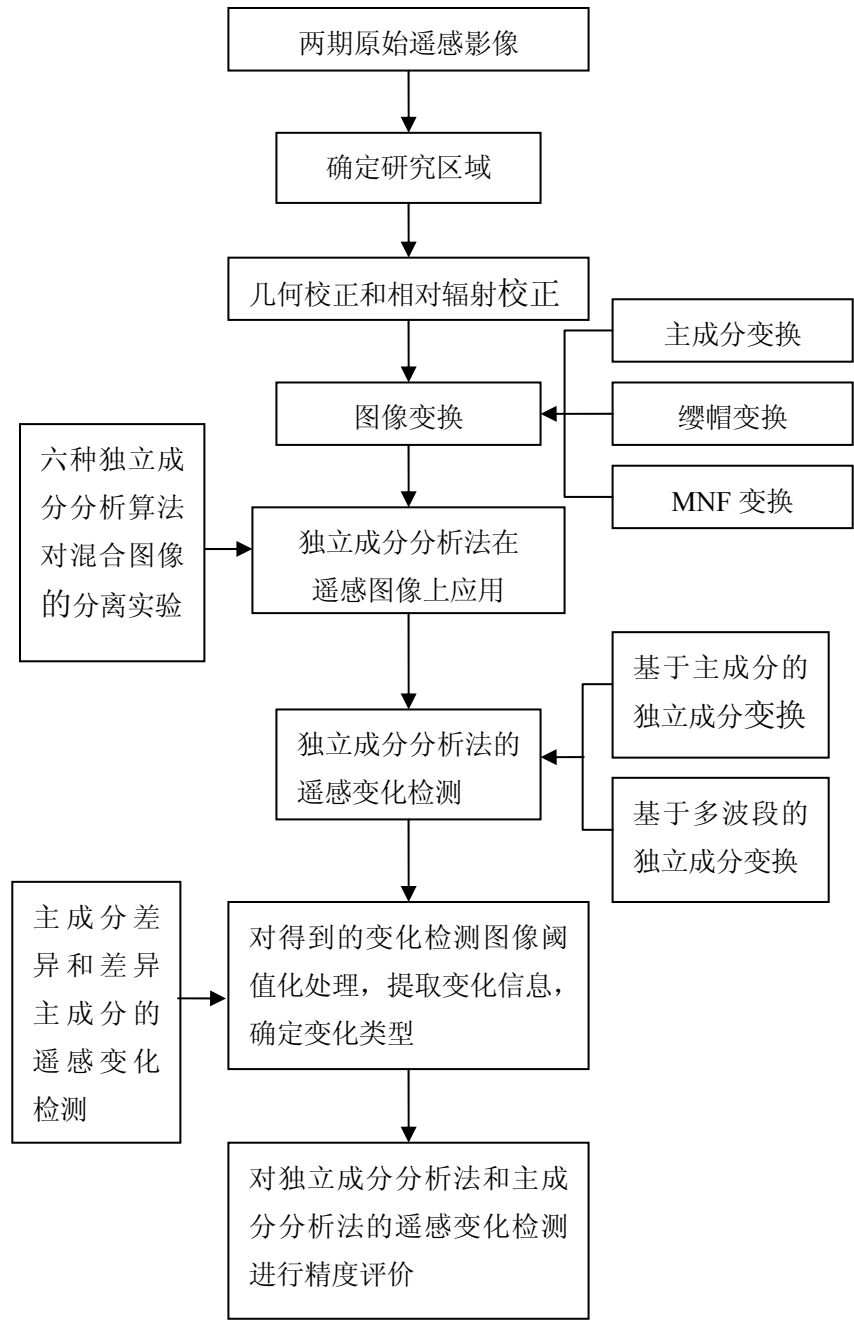


图 3-2 技术路线

第四章 遥感图像的预处理

在进行变化信息检测前，需要考虑以下因素对不同时相图像产生的信息。

(1) 传感器类型的差异：考虑选择相同传感器的图像，甚至选择相同的波段，因为不同中心波长或者不同的波谱响应会导致相同物质具有不同的像元值。

(2) 采集的日期和时间的差异：季节的变化会引起地表植被的差异。不同的时间段也会影响太阳高度角和方位角。

(3) 图像像元单位的差异：不同时相的图像具有相同的像元物理单位和值范围，如同时为浮点型的辐射亮度的图像数据。

(4) 像素分辨率的差异：不同的像素大小会导致错误的变化检测结果。

(5) 大气条件的差异：不同的天气条件会影响光的传输和散射。这样会导致相同的物质在不同大气条件具有不同的像元值。

(6) 图像配准的精度：动态监测是获取相同空间位置的地表变化信息，图像的精度配准对检测结果影响很大。可通过每个文件的精确几何校正来保证，也可以以一个文件作为基准配准另一个时相的文件。可以通过图像的选择、图像的定标、重采样、大气校正和图像配准减少甚至消除以上因素的影响。

4.1 图像的校正

4.1.1 几何校正

遥感图像的几何校是解决遥感图像的几何畸变的问题，其校正方法一般分为光学校正和数字校正两大类。光学校正通常不能对卫星遥感图像，特别是动态遥感图像进行严格的纠正，而遥感数字图像纠正是建立在严格的数学基础上，并可以逐点的对图像进行纠正，因而原则上它可以对任何类型的传感器图像进行严格的纠正。遥感图像几何校正的方法主要有传感器构像方程法、多项式纠正法、共线方程纠正法等。一般在实践中常采用多项式纠正法，其校正包括两个过程，一是图像坐标的空间变换，二是灰度重采样。坐标空间变换是通过变换函数，建立校正前后图像空间坐标间的关系。利用实际选取的控制点坐标，按最小二乘法求出多项式的系数。利用求得的系数和确定的坐标换算函数对全部数据进行坐标变换，即根据变换函数解算每个像元的空间位置，以达到校正的目的。在调用多项式模型时，需要确定多项式的次方数，通常整景图像数据选择3次方。次方数与所需要的最少控制点数是相关的，最少控制点计算公式为 $((t+1)*(t+2))/2$ ，式中 t 为次方数，即1次方最少需要3个控制点，2次方需要6个控制点，3次方需要10个控制点，以此类推（郑明国，2002）。采用多项式法进行卫星影像校正时，对地面控制点（Groundcontrolpoint, GCP）的数量和分布均有要求，它要求GCP在影像中尽可能均匀分布，并要求边缘和四角均要有GCP分布，在实际工作中，常要采用的GCP数量为理论数量的2~3倍。

本文的遥感影像已经经过几何粗校正，只需要进行几何精校正，遥感影像的几何配准可以以单个参照影像（地形图）为基准，对影像进行坐标匹配，也可以以一个时相的影像

为基准来配准另一个时相的影像。因此本文以 1:10000 的中山陵地形图为基准,采用多项式变换对 2006 年的 TM 影像进行几何精校正,精度在半个像元以内。再以配准好的 2006 年 TM 影像对 1998 年 TM 影像进行配准,精度同样控制在半个像元以内。

4.1.2 辐射校正

由于传感器响应特性和大气的吸收、散射以及其他随机因素影响,导致图像模糊失真,造成图像的分辨率和对比度相对下降,这些都需要通过辐射校正复原。辐射校正根据实施的途径可以分为绝对辐射校正和相对辐射校正,绝对辐射校正就是将图像中的测量值校正到地物反射或辐射的真实值,进行绝对辐射校正需要对大气辐射的传输过程进行有效的模拟,确定太阳入射角和传感器视角,以及考虑地形起伏等因素,因此这类方法一般都很复杂,并且得到的绝大多数遥感图像都无法满足上述条件,这样使得绝对校正难以实现。相对辐射校正是一图像作为参考图像,调整另一图像的辐射特性,使之与参考图像一致。经过相对辐射校正,使同一地物在不同的图像中具有相同的辐射值。变化检测是通过分析同一区域在不同时相遥感图像中的辐射值差异来判断该地域是否发生变化。所以若能够使同一地物在不同时相中具有相同辐射特性,就可以通过校正后辐射特性的差异实现变化检测。

本文中的两期 TM 影像目视质量比较好,辐射亮度值正常,不需要再进行绝对大气校正,只需要对其做相对辐射校正。

相对大气校正按照数学基础分为非线性校正和线性校正两种。

由于 2006 年遥感图像内部整体的变动范围比 1998 年大,所以将 2006 年的图像作为参考图像,即主图像,1998 年的图像为待校正图像,即从图像。

(1) 直方图匹配

非线性校正最典型的是直方图匹配,直方图匹配是将校正图像的直方图与参考图像的直方图进行匹配,使两幅图像具有相同或相近的灰度值概率分布,达到两幅图像上同名地物具有相同灰度值的目的。本文先将 1998 年的遥感图像作直方图均衡化,再与 2006 年图像作直方图匹配。此过程有 ENVI 软件来完成。

(2) 伪不变特征法

线性校正法的前提是假设不同时相的图像灰度值之间满足线性关系,这个假设在近似的情况下是成立的。这样就可以通过线性等式来秒速不同时间的灰度关系,用 x 表示参考图像, y 表示待校正图像他们之间的线性关系用表达式表示为:

$$y = ax + b \quad (4-1)$$

式中, a , b 为参数,即增益和偏移量。线性校正分关键是确定等式中的两个参数。通常是根据两时相图像光谱稳定的地物样本点,即伪不变特征要素(Pseudo-Invariant Features,PIF),这些特征要素通常选择相同区域的沥青房顶、砾石面、混凝土停机坪、洁净水体、混凝土、沙地等地物作为PIF,这些地物不会随时间的变化而变化;运用这些伪不变特征点的DN值,利用线性回归的方法求出参数 a 和 b ,得到图像间的线性关系;然后利用公式(4-1)对待校正图像的各波段DN值做线性变换,完成相对辐射校正。

本文采用伪不变特征法对两期TM影像做相对辐射校正,本文以2006年TM影像对1998年影像进行相对辐射校正。经筛选,本文选取了100个点,相关系数均较高,利用线性回归

求解相对辐射校正线性方程系数见表4-1。

表 4-1 最小二乘回归法求解的 a 和 b

波段	增益 a	偏移量 b
Band1	0.8353	22.9692
Band2	0.7435	14.2019
Band3	0.6708	16.1424
Band4	0.6545	22.5009
Band5	0.6521	22.6521
Band7	0.6649	12.0214

(3) 相对辐射校正结果评价

均方根误差(RMSE)用于检验归一化图像与参考图像的相似性^[55]。

$$RMSE_k = \sqrt{\frac{1}{N} \sum_{n=1}^N (y'_k - y_k)^2} \tag{4-2}$$

其中，N表示像元总数， y_k 表示2006年第k波段的像元值， y'_k 表示1998年第k波段的像元值。如果RMSEk的值较小，则辐射校正后的图像与参考图像的辐射值越接近。

表 4-2 两种校正方法与未校正影像各波段均方根误差

波段	未校正前	直方图校正后	伪不变特征法
Band1	13.9053	12.1995	9.2378
Band2	7.2196	6.5040	5.4072
Band3	10.2723	9.8789	8.6765
Band4	13.0008	12.4947	9.4413
Band5	15.9239	15.4201	9.5757
Band7	12.7093	12.5346	12.1776
平均 RNSE	12.17187	11.5053	9.0860

由表 4-2 可知，经辐射校正图像的各波段的 RMSE 均比较正前小，说明相对辐射校正减少了主从图像之间的差异。而伪不变特征法校正后的影像的 RMSE 比直方图校正后较小，直方图法都用了整幅图像的像元，而伪不变特征法只用了整幅图像像元数量的 30%。基于伪不变特征的辐射校正的优点是不受地物变化的影响，而且不会削弱图像之间的地物变化。所以本文采用伪不变特征法的相对辐射校正。

4.2 TM 影像特征分析

4.2.1 TM 各谱段图像特性

光学遥感所接收的电磁波辐射源是地物对太阳光的反射和散射，其波长主要分布在可见光、近红外区域。LANDSAT 的 TM 数据分 7 个波段。

(1) TM1 波长为 $0.45\sim 0.52\mu\text{m}$ ，蓝波段。该谱段对叶绿素和叶绿素浓度敏感，对水体穿透力最大，常用于区分土壤与植被、落叶林与针叶林、近海水域制图，有助于判别水深及水中叶绿素分布以及水中是否有水华等。

(2) TM2 波长为 $0.52\sim 0.60\mu\text{m}$ ，绿波段。该谱段对健康茂盛植物的反射敏感，对水面有一定穿透力，常用于探测健康植物绿色反射率，按绿峰反射评价植物的生活状况，区分林型，树种和反映水下特征。

(3) TM3 波长为 $0.62\sim 0.69\mu\text{m}$ ，红波段。该谱段是叶绿素的主要吸收波段，反映不同植物叶绿素吸收，植物健康状况，用于区分植物种类与植物覆盖率，其信息量大多为可见光最佳波段，广泛用于地貌，岩性，土壤，植被，水中泥沙等方面。

(4) TM4 波长为 $0.76\sim 0.96\mu\text{m}$ ，近红外波段。该谱段对无病害植物近红外反射敏感，对绿色植物类别差异最敏感，为植物通用波段，常用于牧师调查，作物长势测量，水域测量，生物量测定及水域判别。

(5) TM5 波长为 $1.55\sim 1.75\mu\text{m}$ ，中红外波段。该谱段对植物含水量和云的不同反射敏感，处于水的吸收波段，一般 $1.4\sim 1.9\mu\text{m}$ 内反映含水量，用于土壤湿度植物含水量调查，水分状况研究，作物长势分析，从而提高了区分不同作用长势的能力，可判断含水量和雪、云。在 TM7 个波段光谱图像中，一般第 5 个波段包含的地物信息最丰富。

(6) TM6 波长为 $1.04\sim 1.25\mu\text{m}$ ，远红外波段。该谱段可以根据辐射响应的差别，区分农林覆盖长势，差别表层湿度，水体岩石，以及监测与人类活动有关的热特征，作温度图，植物热强度测量。由于林业上用该波段来探测植物病虫害，分辨率比较低，故本文的分析没有用到此波段。

(7) TM7 波长为 $2.08\sim 3.35\mu\text{m}$ ，中红外波段。该谱段为地质学家追加波段，处于水的强吸收带，水体呈黑色，可用于区分主要岩石类型，岩石的热蚀度，探测与交代岩石有关的粘土矿物。

4.2.2 最优波段选择

一般而言，选择最佳波段的原则有 3 点：1) 所选的波段信息量要大；2) 波段间的相关性要小；3) 波段组合对所研究地物类型的光谱差异要大^[56]。基于这 3 个原则，目前应用比较广泛的选取方法有各波段信息量的比较、各波段间信息的相关性比较、最佳指数法、各波段数据的熵和联合熵等方法。

(1) 各波段之间相关性分析

两两波段影像间的相关系数反映出两波段间的信息冗余度，相关系数越大，信息冗余度也就越大。以下是计算出的六波段间相关系数。

表 4-3 1998 年 6 个波段之间的相关系数

	Band1	Band2	Band3	Band4	Band5	Band7
Band1	1.0000	0.9699	0.9661	-0.5652	0.6329	0.9195
Band2		1.0000	0.9872	-0.4645	0.7329	0.9505
Band3			1.0000	-0.5231	0.7115	0.9578
Band4				1.0000	0.1459	-0.3956
Band5					1.0000	0.8316
Band7						1.0000

表 4-4 2006 年 6 个波段之间的相关系数

	TM1	TM2	TM3	TM4	TM5	TM7
TM1	1.0000	0.9574	0.9370	-0.4949	0.7129	0.9044
TM2		1.0000	0.9812	-0.4469	0.7536	0.9040
TM3			1.0000	-0.4935	0.7430	0.9101
TM4				1.0000	0.0547	-0.3834
TM5					1.0000	0.8736
TM7						1.0000

由表 4-3 和表 4-4 计算结果可以看出, TM4 波段与其他波段的相关性较小。因此它的独立性较好。可见光 TM1、TM2、TM3 波段之间的相关性较大, 信息重叠度大, 信息冗余。

(2) 各波段的信息熵与标准差

表 4-5 1998 年和 2006 年各波段的信息熵与标准差

		TM1	TM2	TM3	TM4	TM5	TM7
1998	信息熵	5.2821	4.6122	5.3720	6.0566	5.9119	5.6420
	标准差	11.1670	7.1349	13.8233	16.8623	15.6820	14.9823
2006	信息熵	5.3201	4.5334	5.2033	5.8141	5.8173	5.5499
	标准差	12.4926	7.5094	12.5474	14.1604	15.7090	15.6673

从表 4-5 可知 1998 年的各波段中, TM4 的信息熵和标准差最大, 说明此波段的信息量最丰富。其次是 TM5、TM7。2006 年各波段中 TM5 的信息量最丰富, 其次是 TM4、TM7。

(3) 最佳指数 OIF

最佳指数是美国查维茨提出的, 其理论依据: 图像数据的标准差越大, 所包含的信息量也越大, 而波段间的相关系数越小, 表明各波段图像的独立性越高, 信息冗余度越小^[57]。

$$OIF = \frac{\sum_{i=1}^n S_i}{\sum_{i=1}^n \sum_{j=i+1}^n |R_{ij}|} \quad (4-3)$$

式中, S_i 为第 i 个波段的标准差, R_{ij} 为 i 、 j 两波段的相关系数。OIF 指数越大则说明

波段间的相关性越小，三个波段所包含的信息量越大。通过 OIF 指数公式的计算，表 4-6 中各波段组合的 OIF 指数如下。

表 4-6 两期图像各波段的最佳指数

1998 年			2006 年		
序号	波段组合	最佳指数 (OIF)	序号	波段组合	最佳指数 (OIF)
1	1、2、3	10.9897	1	1、2、3	11.3190
2	1、2、4	17.5855	2	1、2、4	17.9880
3	1、2、5	14.5500	3	1、2、5	14.7328
4	1、2、7	11.7202	4	1、2、7	12.8961
5	1、3、4	20.3725	5	1、3、4	20.3595
6	1、3、5	17.6031	6	1、3、5	17.0293
7	1、3、7	14.0579	7	1、3、7	14.7948
8	1、4、5	32.5223	8	1、4、5	33.5542
9	1、4、7	22.8741	9	1、4、7	23.7396
10	1、5、7	17.5467	10	1、5、7	17.6116
11	2、3、4	19.1519	11	2、3、4	17.8064
12	2、3、5	15.0681	12	2、3、5	14.4348
13	2、3、7	12.4122	13	2、3、7	12.7800
14	2、4、5	29.5403	14	2、4、5	29.7815
15	2、4、7	21.5290	15	2、4、7	21.5290
16	2、5、7	15.0300	16	2、5、7	15.3628
17	3、4、5	33.5879	17	3、4、5	32.8505
18	3、4、7	24.3368	18	3、4、7	23.7133
19	3、5、7	17.7882	19	3、5、7	17.3846
20	4、5、7	34.6135	20	4、5、7	34.7174

从表上可知，OIF 的值最大的是波段 4、5、7 三波段，其次是 3、4、5 和 1、4、5 组合。结合波段之间的相关系数和方差知，最优波段组合以 TM4、TM5、TM7 为最佳。

4.3 图像变换

4.3.1 主成分变换

主成分变换是一种常用的数据压缩方法。由于遥感影像的不同波段之间存在着很高的相关性，直观上看不同波段的图像很相似，所以图像中有相当一部分数据信息是多余和重复的，这对于提取有用信息有很大的影响。主成分变换就是一种去除波段之间多余的信息、将多波段的图像信息压缩到原波段更有效的少数几个转换波段的方法。因此，主成分变换后的各个主成分互不相关，包含的信息内容彼此不重叠，从而大大减少总数据量，消除冗余信息，并使图像信息增强。

主成分分析法的主要步骤是：（1）根据原始多光谱图像（ m 个波段，每个波段有 n 个像素）数据矩阵 X ，计算出它的协方差矩阵 C ；（2）计算协方差矩阵 C 的特征值 λ 与特征向量 U ，由特征方程 $|\lambda I - C| = 0$ 求出特征值 λ_i （ $i = 1, 2, \dots, m$ ），将其按大到小的顺序排列，再解方程 $|\lambda_i I - C| = 0$ （ I 为单位矩阵），求出个特征值对应的单位特征向量 U_i ，即 $U_i = [u_{1i}, u_{2i}, \dots, u_{mi}]$ 。U 矩阵的转置矩阵就是主成分变换的系数矩阵 T 。（3）由主成分变换的表达式 $Y = TX$ ，获得新矩阵 Y ，矩阵的每一行就是主成分变换后的一个主分量。

本文对两期多光谱图像做主成分变换计算出其特征值、特征向量及各特征值的贡献率如下。

表 4-7 1998 年各主成分特征值及贡献率

主分量	特征值	贡献率（%）	累积贡献率（%）
PC1	783.242453	69.84	69.84
PC2	313.346653	27.94	97.79
PC3	17.151203	1.53	99.31
PC4	4.122568	0.37	99.68
PC5	2.953103	0.26	99.95
PC7	0.610423	0.05	100.00

表 4-8 2006 年各主成分特征值及贡献率

主分量	特征值	贡献率（%）	累积贡献率（%）
PC1	792.1662	74.55	74.55
PC2	226.3131	21.30	95.84
PC3	27.4536	2.58	98.43
PC4	10.7768	1.01	99.44
PC5	4.9728	0.47	99.91
PC7	0.9634	0.09	100.00




图 4-1 1998 年 6 个主成分图像




图 4-2 2006 年 6 个主成分图像

从表 4-8 中可以看出两期图像的前三个主分量累积贡献率分别为 99.31%和 98.43%，这表明原 TM 六个波段的信息大多集中在前三个主分量上。经主成分变换后，PC1 图像纹理清晰，消除了阴影影响，地物层次分明；PC2 图像层次不清楚，地类轮廓模糊；PC3 整图模糊不清，图像杂乱。人们常用前三个主分量作假彩色合成，它的优点在于三个主分量互不相关，消除信息之间的相互影响，有助于遥感影像的判读与分类。

4.3.2 缨帽变换

缨帽变换(Tasseled Cap)，是针对植物学家所关心的植被图像特征，在植被研究中将原始图像数据结构轴进行旋转，优化图像数据显示效果，是有 R.J.Kauth 和 G.StThomas 两位学者提出的一种经验性的多波段线性正交变换，因而又称 K-T 变换。与主成分变换不同的是经变换后的新分量不是指向主成分的方向，而是指向另外的方向。变换后留有残余的相关，新分量将光谱特征与自然景观属性联系起来。线性变换并不改变数据结构本身，也不改变地物的相对位置，因此数据结构在变换前后无变化，只改变了观察面或观测角。

缨帽变换数学表达式：

$$u = R^T x + r \quad (4-4)$$

其中 R 是缨帽变换系数， x 代表不同波段的灰度值， r 表示常数偏移量，是为避免在变换过程中出现负值。 u 表示缨帽变换后不同的波段的灰度值。经过缨帽变换可以得到与波段数相同的几个分量，其中前三个分量与地面景物密切相关。第一分量为亮度指数，反映了地物总体反射率的综合效果；第二分量为绿度指数，与地面植被覆盖、叶面积指数及生物量有很大关系；第三分量为湿度指数，反映了地面水分条件，特别是土壤的湿度状态。其余分量为黄度指数及噪声^[58]。

4.3.3 最小噪声分离

最小噪声分离变换（Minimum Noise Fraction Rotation, MNF Rotation）是将一幅多波段图像的多波段信息集中在前几个波段中，主要作用是判断图像的维数、分离数据中的噪声，减少后处理中计算量。

MNF 也是一种线性变换，本质上是含有两次叠置的主成分：

第一次变换是利用主成分中的噪声协方差矩阵，分离和重新调节数据中的噪声（噪声白化），使变换后的噪声数据只有最小的方差且没有波段间相关。

第二次变换是对噪声白化数据进行主成分变换。为了进一步进行波谱处理，检查最终特征值和相关图像判断数据的内在维数。数据的空间被分为两部分：一部分是联合大特征值和相应的特征图像；另一部分与近似相同特征值和噪声图像。

本文使用 MNF 变换的目的主要是去除噪声，以消除噪声在变化检测中的影响。

4.3.4 植被指数

植被指数是反映植被在可见光、近红外波段反射与土壤背景之间差异的指标，在一定条件下能定量说明植被的生长状况。随着遥感技术的发展，植被指数作为表征地表植被覆盖和生长状况的度量参数，已经在环境、生态、农业等领域有了广泛的应用。常用的植被

指数主要有比值植被指数(RVI)、垂直植被指数(PVI)、归一化植被指数(NDVI)、转换型植被指数(TNDVI)等,其中归一化植被指数的应用比较广泛,并能很好的反映植被信息。在遥感影像中,归一化植被指数为近红外波段的反射值与红光波段的反射值之差与两者之和的比值。本文用 TM 遥感图像的 3、4 波段构建植被指数,归一化植被指数的定义公式为:

$$NDVI = (TM4 - TM3) / (TM4 + TM3) \quad (4-5)$$

4.3.5 水体指数

通过对 TM 遥感图像各波段的光谱特性分析可知,水体的反射从可见光到中红外波段逐渐减弱,在近红外和中红外波长范围内吸收性最强,几乎无反射,因此用可见光波段和近红外波段的反差构建水体指数即 NDWI,可快速提取水体信息。由于植被在近红外波段的反射率一般最强,因此采用绿光波段与近红外波段的比值可以最大程度地抑制植被的信息,从而达到突出水体信息的目的。通过光谱分析与实验研究,用 TM 遥感图像的 2、5 波段构建水体指数。

$$\text{水体指数 } NDWI = (TM2 - TM5) / (TM2 + TM5) \quad (4-6)$$

第五章 六种 ICA 算法在图像处理中的实验

现有的各种 ICA 算法一般都能比较有效地从观测得到的混合信号中分离出原始信号，而图像从信号角度看可认为是二维信号，可经扫描成一维信号，所以利用 ICA 算法对混合图像进行分离具有可行性。目前，随着技术的发展出现了各种不同的 ICA 处理算法，这些算法的目标函数和优化算法各不一样。目标函数是根据对源信号各个成分之间的独立性的判据而建立的，主要有互信息最小化判据、最大似然判据、信息最大化判据、负熵最大化判据等基于源信号相互间统计独立性的假设，ICA 可以尽量减少成分间的统计依赖性，从而从混合信号中分离出原始信号，提取出源信号的估计。常常使用 ICA 从一组观测数据中找到隐藏的因子（源信号或特征），从而获得尽可能独立的分量。本文运用六种 ICA 算法对自然图像和 TM 遥感图像进行分离试验，初步探索 ICA 在图像处理中的应用。

5.1 六种 ICA 算法

（1）Efficient ICA 算法

Efficient ICA 是源自适应的，它使用广义高斯分布（一种对称分布）来估计源信号的分布密度。当所有的源信号服从广义高斯分布时，Efica 提供一种渐近优化方法^[59]。

（2）EGLD_ICA 算法

EGLD_ICA 是源自适应的参数模型。它对源信号分布进行建模，其主要优点是考虑了源信号分布的偏斜度，EGLD_ICA 使用了三阶和四阶统计矩以拟合更广泛的分布。源信号分布通过边际分布来估计。像目标函数（contrast function）一样，Score 函数被看作是判断收敛的标准^[60]。

（3）FastICA 算法

FastICA 是一种固定点算法，它使用非高斯性最大作为独立度量从混合信号中提取出源信号。用于超高斯和亚高斯信号的分离。FastICA 的收敛是二次的，比线性收敛（梯度方法的收敛是线性的）更快。FastICA 为非源自适应的^{[61][62]}。

（4）JADE 算法

JADE 算法由 Jean Francis Cardoso 发展而来。该算法使用累计量作为独立性的度量，累计量与信号的高阶统计量有关。JADE 通过最小化高阶累计量来接近独立性。理论上，当所有互累计量为 0 时，各分量就互相独立。JADE 的一个主要缺点是野点对高阶累计量的影响较大。当有野点时，JADE 的应用就受到限制。JADE 还不能分离偏斜的、峰度为 0 的信号，这是因为它仅仅最小化了四阶累计量，三阶（如偏斜度）的影响没有考虑到。JADE 为非源自适应的。

（5）Non-parametric ICA 算法

Non-parametric ICA 方法可以分成两步：白化过程和旋转过程。白化是去相关，以及去相关信号方差的归一化。白化后，Non-parametric ICA 通过把信号旋转到一个合适的角度，来寻找独立性最大的方向。通过最小化目标函数来获得旋转角度。目标函数基于独立性的基本定义，即联合概率密度等于边际概率密度的乘积。为了估计信号的概率密度分布

函数，Non-parametric ICA 使用了核密度估计技术。Non-parametric ICA 是源自适应的无参模型^[63]。

(6) Pearson-ICA 算法

Pearson-ICA 算法结合了固定的非线性目标函数和最大似然方法。在最大似然方法中使用 Pearson 系统来对源信号分布进行建模。Pearson 系统可以用于很多种类的源信号分布。使用 Pearson 系统可以分离偏斜分布与高斯分布具有相同峰度的分布的源信号。由于最大似然方法能提供更快的收敛性，Pearson-ICA 对近高斯分布的源信号比固定的非线性函数收敛更快。应用 Pearson 系统产生源自适应的目标函数，Pearson-ICA 可以分离超高斯和亚高斯信号，以及峰度为 0 的偏斜分布。Pearson-ICA 是源自适应的参数模型^[64]。

以上六种 ICA 算法的主要区别是：在目标函数中，源信号的未知概率密度函数是怎样用合适的非线性来估计或代替的^[65]。

5.2 六种 ICA 算法在图像处理中的实验

5.2.1 自然图像的独立成分分离实验

物质世界存在着许许多多的自然图像，且图像在空间坐标中一般都是相关、不稳定的，这里用自然图像数据进行分离实验。自然图像是二维图像，源图像的大小是 128pixel，按行扫描成为长度为 16384 的一维信号进行处理，它们以向量形式编码。ICA 模型中的向量的每一行代表了一个独立成分，在完成独立成分得到处理结果后按相反的过程还原成二维图像。

3 幅原始图像依次为 smallgirl 图像、lenna 图像和 baboon 图像，如图 5-1 所示。



图 5-1 smallgirl 图像、lenna 图像和 baboon 图像




图 5-2 smallgirl 图像、lenna 图像和 baboon 图像的直方图

表 5-1 自然图像峰度和偏度			
	smallgirl	lenna	baboon
峰度	1.5161	-0.5762	-0.3633
偏度	1.9725	1.45977	1.5200

从表 5-1 和图 5-2 中看出,混合的图像中有超高斯图像(smallgirl)和亚高斯图像(lenna、baboon)。

本文实验使用三幅图像和一幅高斯噪声图像作为实验数据对六种独立成分分析算法进行探索,将 4 幅图像用随机生成的混合矩阵 $A = rand(size(S,1))$ (S 为按行扫描的源图像信号)进行将其混合,得到实验所需要分离的混合图像,6 种 ICA 算法得出的各分量图像如图 5-3 所示:

$$A = \begin{bmatrix} 0.8201 & 0.7754 & 0.0158 & 0.6313 \\ 0.3421 & 0.6902 & 0.6839 & 0.5860 \\ 0.8720 & 0.0180 & 0.8779 & 0.2274 \\ 0.2680 & 0.7015 & 0.4318 & 0.7847 \end{bmatrix}$$

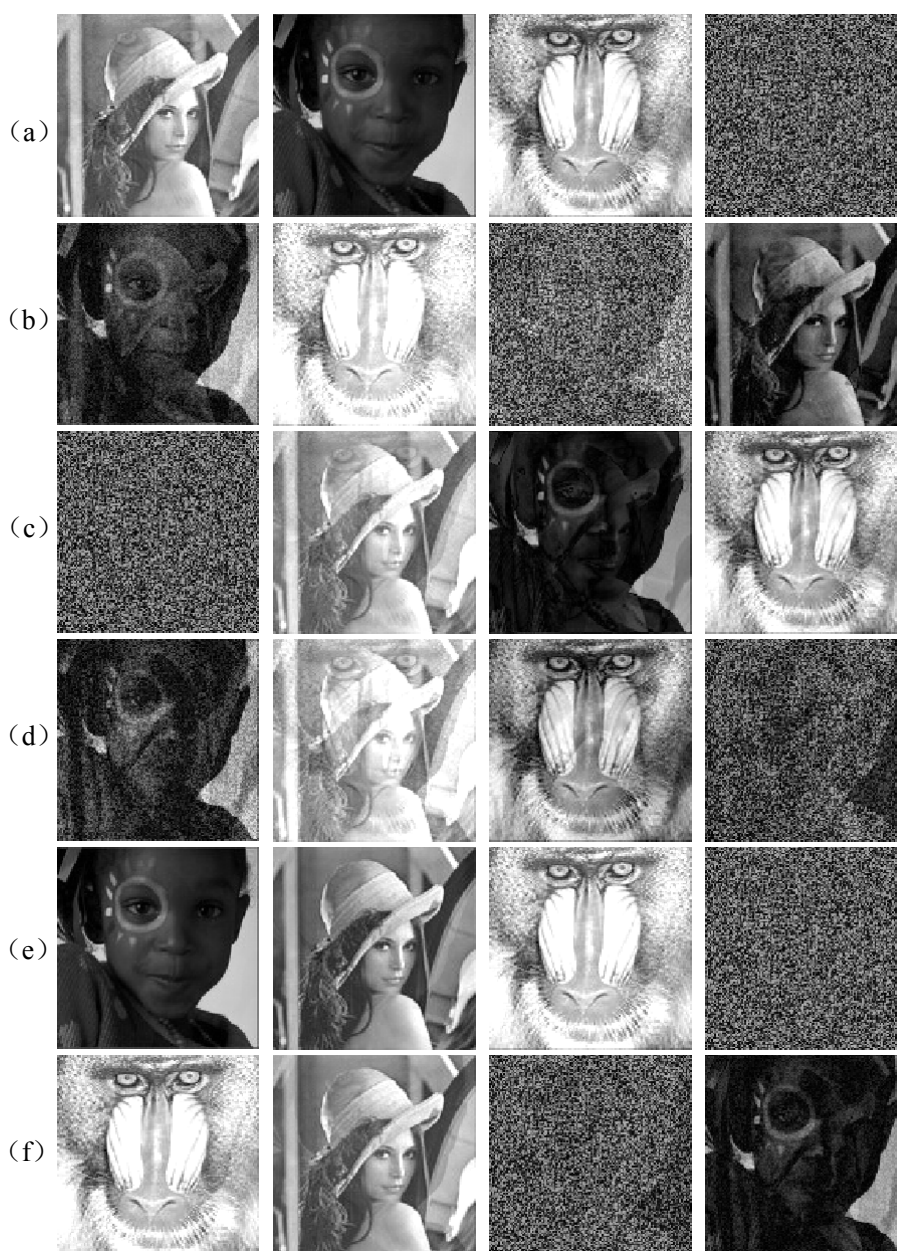


图 5-3 各种 ICA 算法结果: (a) Efficient ICA (b) EGLD_ICA (c) FastICA
(d) JADE (e) Non-parametric ICA (f) Pearson-ICA

5.2.2 ICA 算法的分离性能指标

(1) 串音误差 PI

当通过观测信号成功恢复源信号时, 混合分离矩阵为广义交换矩阵, 每行每列有且只有一个非零元素。根据混合分离矩阵的这个特性, 可以采用分离得到的估计信号与源信号的串音误差作为衡量算法分离效果好坏的性能指标, 串音误差 PI 的定义公式为:

$$PI = \frac{1}{n(n-1)} \sum_{i=1}^n \left\{ \left(\sum_{j=1}^n \frac{|c_{ij}|}{\max_k |c_{ik}|} - 1 \right) + \sum_{j=1}^n \frac{|c_{ji}|}{\max_k |c_{ki}|} - 1 \right\} \quad (5-1)$$

其中 n 表示全局矩阵 $C = WA$ 的维数, c_{ij} 为 C 的第 i 行第 j 列元素。PI 的值越小表示分

离性能越好，当 PI=0 时表示分离信号与源信号完全相同。

(2) 相关系数

相关系数 r 是衡量 ICA 算法分离效果好坏的另一个指标，相关系数是变量之间相关程度的指标。通过计算源信号与估计信号之间的相关系数，来判断估计信号与源信号的相似度。相关系数越大说明分离性能越好，当 r=1 时表示分离信号与源信号相同。

$$r_{XY} = \frac{\sum_{i=1}^N (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^N (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^N (Y_i - \bar{Y})^2}} \tag{5-2}$$

其中，X、Y 表示源信号与分离信号。

表 5-2 六种算法的 PI 性能指标及所用的时间

算法	PI 值	运行时间 (s)
Efficient ICA	0.1072	0.5717
EGLD_ICA	0.3347	3.1405
FastICA	0.2073	0.6243
JADE	0.4063	0.6471
Non-parametric ICA	0.0558	557.0752
Pearson-ICA	0.2471	0.9549

表 5-3 原始图像与分离后恢复图像的相关系数表

算法	smallgirl	lenna	baboon	gauss
Efficient ICA	0.9989	0.9805	0.9735	0.9999
EGLD_ICA	0.9222	0.9037	0.9736	0.9582
FastICA	0.8598	0.9635	0.9655	0.9999
JADE	0.8959	0.7707	0.7849	0.7899
Non-parametric ICA	0.9995	0.9950	0.9874	0.9999
Pearson-ICA	0.8968	0.9793	0.9771	0.9830

从图 5-3 可知，经过 ICA 分离的图像与原始图像的顺序不一致，改变了原来的次序，这说明独立成分分析存在不确定性，无法确定独立成分的次序，并且结果有正负两种情形。不过这些不会影响该算法对实际问题的处理。从 6 种算法分离得到的恢复图像也可以清晰的看到除了 Non-parametric ICA 得到的恢复图像，其他算法的图像都存在混合成分，这些混合成分没有被较好分离出来。从表 5-2 和表 5-3 上可知，无论从 PI 性能指标还是相关系数上看，Non-parametric ICA 对自然图像的分离效果最好，其次 Efficient ICA。但是 Non-parametric ICA 算法运行时间最长，Efficient ICA 最短，为 0.5717s。

5.2.3 TM 图像的独立成分分离实验

遥感影像具有多波段的性质，而遥感影像的灰度值是由地物对某波段的光的反射率所

决定的。因此，不同波段的遥感影像之间具有很大的相关性。由于传感器所获得影像的分辨率的关系，遥感影像的像元往往是混合像元，也就是说，在一个像元里面包含有与之对应的地面的多种地物的信息。

独立成分分析算法初始应用即是利用算法的分离特性，应用统计信息将源信号相互独立的混合信号分离出来，而分离出来的信号是源信号的一种估计。因此，应用独立成分分析算法对多光谱遥感图像进行分离，当多光谱遥感图像的谱段足够多，多到和地物的类型相等时，理论上认为分离出来的结果谱段图像正好对应于每种地物的光谱反映。因此，只要找到分离结果图像和地物之间的对应关系，结果图像就直接是该地物的一种分类结果，图像上反映的信息就是该地物或非该地物了。但是由于地物的多样性或卫星的技术不可能会有和地物对应多的传感器，也就不可能有如此多的谱段与地物一一对应，所以独立分量分析算法只能使得分离得到的每个结果谱段里尽可能地集中某种地物的信息，使得不同地物之间的分离度增大，从而提高多光谱遥感图像的目视解译和分类精度。




图 5-4 独立成分分析对多波段图像的分离原理

在 TM 图像的分离试验中本文选择 2006 年 TM 图像的 1、2、3、4、5、7 六个波段进行分离试验，此数据是通过 MNF 变换进行消噪后的数据。用随机混合矩阵 $A = rand(size(S,1))$ （ S 为按行扫描的源图像信号）将六波段图像进行线性混合。6 种 ICA 算法分离得到的恢复图像如图 5-5：

$$A = \begin{bmatrix} 0.1958 & 0.8090 & 0.4324 & 0.1838 & 0.6789 & 0.7051 \\ 0.9924 & 0.3565 & 0.7492 & 0.4979 & 0.4035 & 0.5586 \\ 0.8023 & 0.0732 & 0.0392 & 0.5178 & 0.9350 & 0.7566 \\ 0.4242 & 0.5910 & 0.9463 & 0.9942 & 0.4795 & 0.9955 \\ 0.7289 & 0.9102 & 0.7637 & 0.8549 & 0.2318 & 0.9624 \\ 0.4984 & 0.1938 & 0.5588 & 0.9624 & 0.3963 & 0.5351 \end{bmatrix}$$




图 5-5 各种 ICA 算法结果：(a) Efficient ICA (b) EGLD_ICA (c) FastICA
(d) JADE (e) Non-parametric ICA (f) Pearson-ICA

从 6 种算法的到恢复图像上看，六种算法分别得到的独立分量同样存在无序性，而且每种算法得到的六个独立分量中，有 4 个独立分量图含有较明显的地物信息，其余两个独立分量图像呈现地物就比较模糊。如第一组独立分量，其第一、三、四、五分量地物较清楚，第二和第六分量图像，地物混杂，模糊不清。六种 ICA 算法都能分离出了植被的信息，呈现明显的白亮色，这对于植被信息的提取有重要的作用，由于耕地的光谱跟植被信息的很相近，所以在分离出来的植被信息图像中可以看到耕地的信息没有呈现明显的亮色，而是比植被信息的亮色稍浅一些；Efficient ICA、EGLD_ICA、FastICA、Non-parametric ICA、Pearson-ICA 五种算法都能分离出水体的信息，在这些图像中，水体呈现白亮色，JADE 分离出部分水体信息；除了 JADE 算法外，其他算法在一定程度上能把建设用地的信息分离出来。

6 种独立成分分析分离得到的植被分量图和水体分量图与 ERDAS 软件得到的植被指数与水体指数的相关系数比较，如表 5-4。同时表 5-5 显示了 6 种 ICA 算法程序的运行时间与遥感图像的波段个数和图像的大小之间的关系进行比较。




图 5-6 2006 年植被指数与水体指数图

表 5-4 分离得到的植被和水体分量与植被指数和水体指数的相关系数

ICA 算法	消噪前		消噪后	
	NDVI	NDWI	NDVI	NDWI
Efficient ICA	0.8708	-	0.9847	0.5310
EGLD_ICA	0.8343	0.2116	0.8762	0.2873
FastICA	0.9651	0.2372	0.9819	0.3060
JADE	0.9471	0.1200	0.9636	0.3233
Non-parametric ICA	0.9825	0.5941	0.9884	0.6017
Pearson-ICA	0.9664	0.5085	0.9839	0.5103
缨帽变换	0.9899	0.3898		

从表 5-4 中计算的相关系数值上看，消噪处理后的植被分量与水体分量的分离效果明显提高，尤其是 Efficient ICA 算法，未消噪前水体分量没有被分离出来，消噪处理后水体分量不仅被分离出来，而且植被分量更加接近植被指数。消噪处理后的 6 种 ICA 算法中，Non-parametric ICA 算法分离得到的植被信息和水体信息图像最好，其次是 Efficient ICA。

表 5-5 ICA 程序运行的时间与波段个数和图像大小的关系（单位：s）

ICA 算法	256×256 像元		512×512 像元	
	3 个波段	6 个波段	3 个波段	6 个波段
Efficient ICA	0.6539	1.8083	2.2530	5.4258
EGLD_ICA	26.6498	72.0793	91.2557	未收敛
FastICA	2.2421	5.0674	11.3323	12.5804
JADE	0.4116	3.9795	0.7284	4.6700
Non-parametric ICA	801.8991	8267.9729	3513.5076	10 小时以上
Pearson-ICA	1.0886	11.6970	3.1467	16.6292

从表 5-5 可知，波段数越多，图像数据越大，ICA 程序运行消耗的时间就越多。尤其是 Non-parametric ICA 算法 6 个波段消耗的时间长达 2 个小时以上，而 JADE 算法消耗的时间最短，但是其分离效果不好。所以总体上看，Efficient ICA 算法效果较好，其程序运行消耗的时间只有 5.4258s，分离效果也较好。

第六章 独立成分分析在多时相遥感图像变化检测中研究

6.1 多时相遥感变化检测的理论

多时相反映了一组遥感影像在时间系列上所具有的特征。凡是在不同时间同一地域获取的一组影像、地图或地理数据,都可视为“多时相”数据。遥感影像变化检测是遥感瞬间视场中地表特征随时间发生的变化引起两个时期影像像元光谱响应的变化。遥感变化检测是遥感信息科学、地球系统科学、统计学和计算机技术等学科技术交叉后新的增长点,代表了当前遥感数据处理技术发展的方向。

现将常用的遥感变化检测方法概括总结为以下几种。

(1) 图像差值法

此方法是应用最广的遥感变化检测方法。它是将两个时相的遥感图像按波段进行逐像元相减,从而生成一幅新的代表两时相间光谱变化的差值图像。在新生成的图像中,图像值为正或者为负则是辐射值变化的区域,而没有变化的区域图像值为 0。差值图像的亮度值常近似高斯分布,没有变化的像元多集中在均值周围,而变化的像元分布在直方图的两翼^[66]。

图像差值法作为变化检测的方法,是最简单的、最直观的方法。而对于多通道不同时相图像的变化,在数学上很容易实现,但由于各种传感器的通道之间往往是互为相关的,图像之间也互为相关,所以在求图像差值时会存在许多问题,可能会出现很多噪声和损失一些信息。图像差值法一般应用于单波段的两幅图像中,以灰度值为考虑对象,它的精度也依赖于图像配准的精度。

(2) 图像比值法

图像比值法是将不同时相的遥感影像对应波段进行逐像元相除^[67]。通过对不同时相影像做相对辐射校正,得到的比值图像增强了变化信息,其中像元比值为 1 或者近似为 1 的认为是未发生变化的区域,像元比值明显高于或低于 1 的认为是发生变化的区域。比值法通常采用变化阈值作为标准划分变化与非变化区域,这时变化阈值的选择就成为比值法变化检测是否有效的关键。比值法和差值法一样都简单、直观,易掌握,变化检测速度快,但这种方法很难考虑到所有因素的影响,容易造成大量信息的流失,同时该方法对图像的配准精度要求很高。

(3) 植被指数差值法^[68]

植被指数差值法是利用光学传感器近红外波段与红波段对植被的显著的响应差,通过比值突出植被信息,再通过阈值提取植被信息和非植被信息。由于植物普遍对红光强烈吸收和对近红外光强烈反射,因此红光和近红外波段之间的比值有利于提高光谱差异。利用波段间比值图像主要有两个优点:不同地物特征的光谱响应曲线差异可能会在比值图像中得到进一步增强;比值能压抑地形效应并对辐射差异进行一定程度的归一化。

(4) 分类后比较法

首先对研究区的不同时相的影像进行各自分类,获得两个或多个分类图像,然后比较

影像同一位置分类结果,进而确定变化信息的位置和类型。此方法优点是可以不考虑影像的获取时间的一致性,以及影像间辐射校正、匹配等问题。它除了确定变化的空间范围外,还可以提供关于变化性质的信息,如由何种类型向何种类型变化等,缺点是必须进行两次图像分类,变化分析的精度依赖于图像分类的精度,可能会夸大变化的程度^[69]。

分类后比较是一种经典的方法,在单个时相分别分类,并进行相互比较后,获得变化信息数据,从而完成了动态变化检测的过程。该方法在外界某些特殊情形下有其独特的优点,尤其是在传感器不同,数据不能融合的情况,或者当两时相影像质量差异较大时,该方法更显优势。但该方法精度依赖于两时相各自分类的精度。分类后比较法无法发现同一地类内部的小变化:精度较低,变化提取的精度大致等于各时相影像分类精度的累积,这一方法明显受到单独分类误差的影响,从而会不可避免地夸大变化的程度。

(5) 主成分变换法

主成分分析法的基本思想是对一组相关的多元随机变量,通过构造一系列线性变换,将原随机变量所包含的信息集中到少数几个互不相关的变换结果分量中,从而达到冗余压缩和信息集中的目的^[70]。

1) 差异主成份法

两时相的影像经纠正、配准后,先对影像进行差值计算,再取差值绝对值,从而得到一个差值影像。显然,这个影像里集中了原两时相影像中绝大部分的变化信息,而滤除了影像中相同的背景部分,在此基础上,再对差值影像做主成分变换。差值影像作主成分变换后的第一分量集中了该影像的主要信息,即原两时相影像的主要差异信息,这个分量可以被认为被提取出来的变化信息,进一步确认变化信息的类型。

2) 主成分差异法

两时相影像作主成分变换后相减的第一分量已经涵盖了几乎所有的变化信息。因此我们就认为这一分量属于影像的变化信息。主成分差异法首先对两时相的多光谱图像分别进行主成分变换,得到的相应主成分再做差值运算,一般取第一主成分的差值影像作为变化信息图。

3) 多时相图像主成分变化法

这种方法用于减少光谱波段数目的多变量分析技术,将两时相的波段数据组成一个波段组。通过主成分变换后,由于变换结果前几个分量上集中了两个影像的主要信息,而后几个分量则反映出了两影像的变化信息,因此可以抽取后几个分量进行波段组合来产生出变化信息^{[71][72]}。

在这些常用的遥感变化检测方法中,主成分分析应用最为广泛。它是通过 PCA 变换,以消除多时相遥感图像间的相关信息,从而使得变化信息在变换后的各成分图像上得到增强。PCA 是基于二阶统计的方法,只有当信号的统计分布符合高斯情况时,PCA 才能完全消除信号间的相关信息,而对于非高斯信号则只能去除信号间的二阶相关信息。但在多时相遥感图像中,各种地物的光谱特性并不都满足高斯分布,因此经过 PCA 变换的各成分图像间仍然存在高阶相关信息,而这些相关信息会影响到变化信息的检测。因此,如果有一种数据变换方法能够有效地消除多时相图像间的各种相关信息,特别是高阶相关信息,则对于变化信息的检测具有非常重要的意义。独立成分分析是近年出现的一种信号处理方法,

不仅能够消除多变量数据中的二阶相关信息,而且能够消除数据间的高阶相关。因此,ICA 变换比 PCA 更能够消除信号之间的关联特性。本文根据 ICA 能够消除多图像间相关信息的特性,将其运用到变化检测中,以提高变化检测的精度。

6.2 基于独立成分分析的多时相遥感图像变化检测

多时相遥感图像变化检测是通过分析不同时相的图像间的差异来实现变化信息的检测。由于遥感各波段图像之间存在着大量关联信息,这样使得直接针对原始图像的变化检测算法实现比较困难,所以将原始遥感数据经过某种变换以消除图像间的关联信息是实现变化检测的一种有效途径。

在遥感图像中,每幅图像都是由多种地物混合组成,如果各种地物的光谱特性都符合高斯分布,则可以通过使用混合高斯模型模拟遥感图像。混合高斯模型在图像处理和分析中已经被广泛地应用,也取得了比较理想的效果。经研究表明,每个信号源(即各种地物的光谱信息)在多时相遥感图像上的统计特性并不完全符合高斯分布。这样基于二阶统计特性的处理方法(如 PCA)就难以有效地实现多时相遥感图像分析。为了克服基于二阶统计处理方法的不足,需要使用高阶统计方法处理多时相遥感数据,因此扩展到使用高阶统计的分析技术是一种解决的途径。而 ICA 作为一种处理高阶统计的数据分析方法,我们将其用于多时相遥感图像分析,实现变化检测。

在本文列出的算法中,应用 ICA 变换,使得变化信息在独立成分中得到有效地分离。多时相遥感图像 X 由独立源信号组成,如下描述:

$$X = AS = a_c S_c + a_n S_n \quad (6-1)$$

其中 $X = \{x_1, x_2, \dots, x_n\}$ 是多时相遥感图像, $S_c = \{s_{c1}, s_{c2}, \dots, s_{cp}\}$ 表示有 p 个独立源信号组成的变化地物信息, $S_n = \{s_{n1}, s_{n2}, \dots, s_{nq}\}$ 表示 q 个非变化源信号组成的非变化地物信息, $a_c = \{a_{c1}, a_{c2}, \dots, a_{cp}\}$ 和 $a_n = \{a_{n1}, a_{n2}, \dots, a_{nq}\}$ 分别是变化地物和非变化地物组合系数。为了得到独立成分,关键是求解矩阵 W , 使得其满足。

本文应用独立成分分析的特性来进行遥感影像的变化检测,由于前、后时相影像包含多个波段数据,所以本文从两个方面研究独立成分在遥感影像变化检测的应用。

(1) 基于主成分的独立成分分析

由于两期遥感图像是多波段的,所以先对两期图像分别进行主成分变换,取他们的第一、二主成分图像作为输入信号进行独立成分变换。其步骤图为:

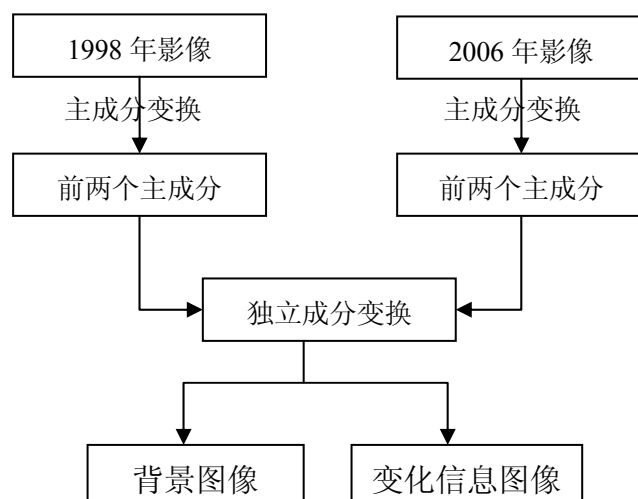


图 6-1 基于主成分的独立成分分析流程图

(2) 基于多波段的独立成分变换

本文选择遥感图像的最佳三波段组合作为实验数据，取两期最佳的同一波段组合作为独立分分量的输入信号，进行独立成分分析，得到变化信息。前面最优波段选择结果是波段 4、5、7 三波段信息量最丰富，所以选择这三个波段做独立分量的输入信号，进行独立成分分析。如图 6-2 所示：

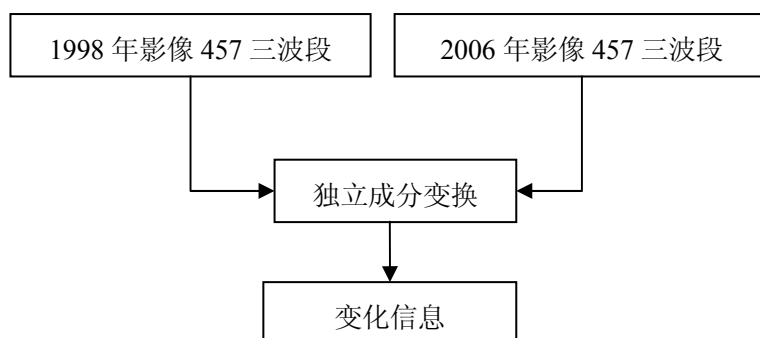


图 6-2 基于多波段的独立成分变换流程图

6.3 变化检测分析

本文使用基于主成分的独立成分分析和基于多波段的独立成分分析两种方法多研究区域进行变化检测，同时将变化检测结果与两种应用广泛的主成分分析法(主成分差异和差异主成分)变化检测结果进行比较。独立成分分析检测方法使用 Matlab 软件，主成分分析使用 ERDAS 软件的 Model Maker。

6.3.1 变化检测结果图

(1) 基于主成分的独立成分分析结果图




图 6-3 基于主成分的独立成分分析结果图

从图 6-3 可知，变化检测实验结果得到了四个独立成分，其中第一独立成分水体信息明显，水体呈黑色。第二独立成分显示了植被信息、耕地和建设用地的信息，植被呈白亮色，耕地比植被稍浅一些，建设用地呈灰色。与实际情况相比，前两个独立成分没有显示出变化信息。而第三、四独立成分显示变化信息，其白色区域为变化区域。第三独立成分图像主要表明了水的变化，这与实际情况中两期水体变化相符合，而第四个独立成分图像显示了其他地物的变化信息，与实际情况相符。

(2) 基于 4、5、7 三波段的独立成分分析结果图




图 6-4 基于 4、5、7 三波段的独立成分分析结果图

从图 6-4 看，变化检测实验结果得到六个独立成分图像，其中第一、二、三独立成分显示了变化区域的信息，其白色区域为变化区域。第一独立成分图像主要表明了建设用地转化为农田草地的变化信息，第二独立成分图像主要表明了水的变化，第三独立成分图像主要表明了除水的变化外的其他地物变化，这一独立成分图像同时也包含了第一独立成分图像上显示的变化信息，只是第一独立成分显示的建设用地的光谱与其他同是建设用地的光谱不同而已，但是这些变化区域信息与实际情况相符合。而第四个独立成分显示了植被信息和建设用地的信息。第五独立成分图像模糊，没有明显的地物信息。第六独立成分水体信息明显，水体呈黑色。后三个独立成分与实际情况相比并未显示变化信息。

(3) 主成分分析法




图 6-5 主成分差异法




图 6-6 差异主成分法

6.3.2 变化信息的提取

变化检测能够检测出由 T1 时刻到 T2 时刻变化区域的具体位置和分布。变化区域的提取主要包括阈值法、区域生长法、聚类法以及人机交互描绘法。

阈值法能有效使用于经图像差值法、PCA 分析、交叉相关分析等处理后的影像上，其关键在于从变化自动发现后的影像上自适应获得变化阈值，有时往往需要多个阈值分层提取各种变化。区域生长法较适用于经光谱特征变异法、波段替换法、假彩色合成法处理后的影像，种子点的选取往往需要人机交互确定，通过区域生长提取变化范围时除采用影像本身的光谱或灰度相似性外，挖掘纹理、结构等复合信息综合提取变化范围有助于提高结果的可靠性与准确性。聚类法需经变化信息自动发现后，综合利用两时相影像合成后的多谱段影像信息的方法。人机交互描绘法适合于上述方法失效的复杂情况，通过人机交互解译，从变化信息特征增强的图像中手工描绘出变化区域。解译的基本要素包括色调、颜色、大小、形状、纹理、结构、高度、阴影、组合构型和所处的地理位置等。人机交互解译最大优点是灵活，并且由于加入了解译者思维和判断，所以信息提取结果精度相对较高。其缺点是需要人机交互逐一提取各变化处的区域范围，难以分层成批处理，工作量大，自动化程度不高。

本文得到的变化检测图都是灰度图像，所以本文采用阈值法提取变化区域，根据阈值选取的方法不同，主要算法有直方图阈值法，迭代法和大津法。其中应用最广泛的就是大津法，又叫最大类间方差法，简称 Otsu。Otsu 阈值化方法是一种自动的非参数非监督的阈值选择法，它基于一种判别式测度准则，最佳的阈值在该测度函数取最大时得到。该方法计算简单，仅需要计算灰度直方图的零阶和一阶累积矩，并且 Sahoo^[73]等人通过实验比较证明，Otsu 法是一种很好的阈值化方法。然而，在实际图象中，由于噪声干扰等因素的影响，使得图象的灰度直方图分布不一定出现明显的峰和谷，此时仅利用灰度直方图得到的阈值并不能使图象分割得到满意的结果，甚至还产生严重的分割错误。原因是像素灰度值仅反映了像素灰度级的幅值大小，并没有反映出像素与邻域的空间相关信息^[74]。基于这一点，刘建庄和栗文清提出了二维 Otsu 自动阈值分割法，该方法建立了既能反映像素点的灰度分布又能体现像素点与其邻域空间相关信息的灰度均值二维直方图，最佳的阈值是在一

个二维的类间方差测度准则取最大值时得到的一个二维矢量，并以此二维矢量作为分割门限进行图像分割，从而提高图像分割的抗噪声能力。所以本文采用二维 Otsu 自动阈值分割法进行变化信息的提取。

(1) 二维 Otsu 阈值分割算法

设图像的灰度等级为 L ，即像素的邻域平均灰度等级为 L ，计算每个像素点邻域的平均灰度，由此形成一个二元组像素的灰度值 i 和它的邻域灰度的平均值 j ，设二元组 (i, j) 出现的频数 $f_{i,j}$ 则可以定义相应的联合密度 $P_{i,j}$ ：

$$P_{i,j} = f_{i,j} / N \quad i, j = 1, 2, \dots, L \quad (6-2)$$

式中的 N 为图像总的像素点数， $N = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} f_{i,j}$ ，并且 $\sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P_{i,j} = 1$




图 6-7 二维直方图的平面投影示意图的四象限划分

假定二维直方图存在两类 C_0 (I) 和 C_1 (III)，分别代表目标和背景（如图 6-7 所示），且具有不同的概率密度函数分布。设阈值 (s, t) ，那么两类的概率分别为

$$W_0 = \sum_{i=1}^s \sum_{j=0}^t P_{i,j} = W_0(s, t) \quad (6-3)$$

$$W_1 = \sum_{i=s+1}^{L-1} \sum_{j=t+1}^{L-1} P_{i,j} = W_1(s, t) \quad (6-4)$$

两类对应的均值矢量为

$$\bar{u}_0 = (u_{0i}, u_{0j})^T = (\sum_{i=0}^s \sum_{j=0}^t iP_{i,j} / W_0, \sum_{i=0}^s \sum_{j=0}^t jP_{i,j} / W_0)^T \quad (6-5)$$

$$\bar{u}_1 = (u_{1i}, u_{1j})^T = (\sum_{i=s+1}^{L-1} \sum_{j=t+1}^{L-1} iP_{i,j} / W_1, \sum_{i=s+1}^{L-1} \sum_{j=t+1}^{L-1} jP_{i,j} / W_1)^T \quad (6-6)$$

二维直方图上总的均值矢量为

$$\bar{u}_T = (u_{Ti}, u_{Tj})^T = (\sum_{i=0}^{L-1} \sum_{j=0}^{L-1} iP_{i,j}, \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} jP_{i,j})^T \quad (6-7)$$

假定远离直方图对角线的 $P_{i,j}$ 为零，即 C_0 ， C_1 分别落在图 6-7 中 I、III 象限，II、IV 象限的 $P_{i,j}$ 可以忽略不计，则可以得到一个类间离散测度（阈值选取准则）：

$$\begin{aligned}
S_B(s,t) &= W_0(s,t)(\bar{u}_0 - \bar{u}_T)^T (\bar{u}_0 - \bar{u}_T) + W_1(s,t)(\bar{u}_1 - \bar{u}_T)^T (\bar{u}_1 - \bar{u}_T) \\
&= W_0[(\bar{u}_{0i} - \bar{u}_{Ti})^2 + (\bar{u}_{0j} - \bar{u}_{Tj})^2] + W_1[(\bar{u}_{1i} - \bar{u}_{Ti})^2 + (\bar{u}_{1j} - \bar{u}_{Tj})^2]
\end{aligned} \quad (6-8)$$

那么最佳的阈值 (s', t') 满足下式

$$S_B(s', t') = \max \{S_B(s, t)\} \quad (6-9)$$

(2) 研究区域变化检测阈值处理结果

本文运用二维 Otsu 阈值分割算法提取变化区域, 将大于阈值的区域设为白色即变化区域, 小于阈值的区域设为黑色即背景区域。




图 6-8 基于主成分的独立成分变换




图 6-9 基于三波段的独立成分变换




图 6-10 主成分差异




图 6-11 差异主成分

6.3.3 变化类型的确定

变化类型的确定只针对发生变化的影像区域，确定变化类型的方法主要有人机交互解译、自动分类识别以及模板匹配等方法。其中比较常用的方法是分类法，目前已经涌现出不少研究遥感分类的新方法，效果较好的方法主要有人工神经网络法、小波分析法、决策树分类法、模糊数学方法、多元数据的专家系统法等，但这些方法的本质仍离不了非监督分类和监督分类的思想。监督分类和非监督分类的区别在于是否有已知训练样本的分类模板，若没有一定的训练样本，一般只能采用非监督分类的方法。监督分类，是在分类之前需要对研究区进行实地抽样调查，结合人工目视判读，对遥感影像上地物的类别进行深入的研究，使计算机按照人的这些先验知识，用已知类别的特征来“训练”判读函数，完成对整个图像的分类。而非监督分类仅仅根据遥感影像地物的光谱特征的分布规律来分类。它只是对不同类别进行区分，并不确定类别的属性；其类别属性是通过各类地物的光谱响应曲线进行分析，以及与实地调查相比较后确定的。这种方法虽然受人为因素的影响较小，不需要对地面信息有详细的了解，但“同物异谱、同谱异物”等现象的大量存在，其分类结果一般不如监督分类好。人机交互解译是以两期遥感图像为背景图层，同时叠加变化信息的提取模板来判断变化区域的变化类型。解译时，按照栅格影像中各地类的色调、形状、位置、纹理、阴影、大小等判读。此方法大大提高变化检测的精度，但工作量较大。本文研究区域变化区域较小，所以采用人机交互判读的方法确定变化区域的类型。

本文将四种方法得到变化检测阈值处理结果作为变化信息提取的模板，为了简单，本文将基于主成分的独立成分变换法和基于三波段的独立成分变换法两种方法得到的变化信息图层合并到一个图层中，然后以 1998 年和 2006 年 TM 影像的假彩色合成的图像（RGB432）为背景，再覆盖上四种方法得到的变化信息模板图层，根据两期遥感图像各地类的色调、形状、位置、纹理等对变化信息进行判读，从而得到两期图像上变化信息的位置和变化类型。本文将研究地区的类型分为林地，农田草地，水体，建设用地和其它用地五类。它们目视解译标志主要有：1) 林地，呈条带状或片状分布，颜色为深红色，影像纹理较平滑、细腻；2) 农田草地，呈片状分布，颜色为浅红色；3) 水体，几何特征明显，呈片状分布或自然弯曲，颜色为深蓝色，影像纹理细腻；4) 建设用地，几何特征明显形状多样，颜色为绿色，影像纹理粗糙；5) 其它用地，颜色为白色。它们的变化类型见表 6-2，在两期图像上的对应的变化区域的地域类型图像见附图。

表 6-1 1998 年~2006 年研究区域变化检测的结果

方法	检测得到的变化像元数	实际变化像元数	实际非变化像元数
主成分差异	11978	10985	993
差异主成分	12158	11505	653
基于主成分的 ICA	15355	13007	2348
基于多波段的 ICA	14884	13317	1567

从表 6-1 上看，基于主成分的 ICA 检测方法检测的总变化像元数最多，且实际变化的像元数也最多。主成分差异法检测到的总变化像元数最少，基于多波段的 ICA 算法检测的

实际变化像元数最多。

表 6-2 1998 年~2006 年中山陵土地类型转移像元数

转移 类型	目视 解译	主成分 差异	差异 主成分	基于主成分的 ICA	基于多波段的 ICA
林地-水体	34	29	28	33	33
林地-农田草地	745	379	428	539	471
林地-建设用地	1915	1478	1485	1574	1658
林地-其他用地	32	29	27	29	32
水体-林地	5	3	5	5	4
水体-农田草地	173	148	153	165	169
水体-建设用地	247	214	238	219	246
水体-其他用地	4	5	4	3	5
农田草地-林地	721	446	485	701	512
农田草地-水体	99	63	72	88	77
农田草地-建设用地	5539	4638	4796	4997	5459
农田草地-其他用地	59	48	51	42	45
建设用地-林地	991	295	310	874	835
建设用地-水体	288	137	143	217	286
建设用地-农田草地	3028	2637	2812	3033	2986
建设用地-其他用地	299	258	272	276	297
其他用地-林地	17	10	11	15	12
其他用地-水体	2	0	1	1	0
其他用地-农田草地	38	34	36	37	37
其他用地-建设用地	168	135	148	158	154
总和	14403	10985	11505	13007	13317

从表 6-2 可知，1998 年到 2006 年间研究区域土地变化类型转移像元数上看，研究区域的变化类型主要是农田草地与建设用地之间的变化，从整体上看基于多波段的 ICA 检测到的变化的总像元数最接近实际变化像元数。

6.3.4 变化检测结果的评价

变化检测结果的精度对于评估不同检测方法，地物时相变化规律分析理论决策是十分重要的，它表明了变化检测结果的可靠性。常用的精度评估指标有检测率、漏检率、虚检率、Kappa 系数等。变化检测类似于图像分类，变化检测的结果只有变化与未变化两类。因此对变化检测的精度进行有效的量化分析，是评价某种变化检测方法性能的客观依据。

根据变化信息检测的不同层次，将变化检测的性能评估分为三个层次

- 1) 像元的检测评估，即判断是否检测出该像元处发生的变化。
- 2) 特征的检测评估，即判断是否检测出该特征发生的变化。

3) 目标级的检测评估, 即判断是否检测出该目标发生的变化。

地物的变化包括地物结构的变化和地物属性的变化, 目前变化检测结果的评估基本上是集中在地物结构变化的分析上。而在针对地物结构变化的性能主要评估变化检测算法对变化区域的检测性能, 即像元级评估, 而对特征级和目标级的评估则很少涉及, 主要原因是特征级与目标级的性能评估没有找到客观的评价体系和参考标准。由于像元级的变化检测基本上都需要是通过图像分类来实现的, 所以变化检测结果的评估方法主要来源于遥感图像分类的精度评价方法, 从图像分类的分类误差矩阵演化来的变化检测误差矩阵, 以及分参量 Kappa 系数成为定量的变化检测性能主要评估方法。

(1) 误差矩阵评估

从图像分类的分类误差矩阵演化来的变化检测误差矩阵作为一种定量的变化检测性能评估方法, 是目前变化检测性能评估的主要方式^[2]。一种简单的变化误差矩阵如表 6-3 所示。在变化检测的变化误差矩阵中, 在没有检测误差情况下存在变化与非变化像元两种, 分别记为 C_t 和 C_f , 利用变化检测方法得到变化与非变化像元记为 C_0 和 C_1 。

表 6-3 变化误差矩阵

变化检测结果	实际变化像元 C_t	实际的非变化像元 C_f
检测出的变化像元 C_0	C_{t0}	C_{f0}
检测出的非变化像元 C_1	C_{t1}	C_{f1}

根据变化检测误差矩阵中各项的定义, 变化检测的性能可以通过以下参数来定量分析:
检测概率:

$$P_{t1} = C_{t0} / C_0 \quad (6-10)$$

虚警率:

$$P_{f0} = C_{f0} / C_0 \quad (6-11)$$

漏警率:

$$P_{t1} = C_{t1} / C_0 \quad (6-12)$$

总的检测误差:

$$P_e = P_{f0} + P_{t1} \quad (6-13)$$

(2) Kappa 系数评估

Kappa 系数是在综合了用户精度和制图精度两个参数的基础上提出的一个最终指标, 它用于评价分类图像的精度。有的学者也用 Kappa 系数来评价变化检测结果的精度^[44], 但使用频率远远赶不上误差矩阵评估参量。令 P_i 表示参考图像中第 i 类像素占整幅图像的比例, P_i 为分类图像中第 i 类像素占整幅图像的比例, P_{ii} 为参考图像与分类图像第 i 类的重合像素占整幅图像的比例, 则 Kappa 系数定义公式为:

$$K = \frac{P_{ii} - (P_i * P_i)}{P_i - P_i * P_i} \quad (6-14)$$

上式可以计算每一类的分类精度, 也可以计算整幅图像的分类精度。值域为[-1, 1],

值越大，表示图象分类精度越好。当分类图像和参考图像完全相同时， $K=1$ ；当分类图像和参考图像完全不同时， $K=-1$ ；如果两幅图像间的变化时随机的， $K=0$ 。在变化检测中，变化检测结果只有两类：变化类 C 和未变化类 U。所以变化类的检测精度 K_c 可以由公式 (6-15) 表示：

$$K_c = \frac{P_c - (P_c * P_{c.})}{P_{c.} - P_c * P_{c.}} \tag{6-15}$$

其中， P_c 表示变化检测得到的变化像元与实际变化像元重合的部分占总像元的比例， $P_{c.}$ 是实际变化像元占总像元的比例， $P_{.c}$ 是变化检测得到的变化像元占总像元的比例。

表 6-4 变化检测精度评价

检测方法	虚警率	漏警率	检测误差	总检测概率	Kappa 系数
主成分差异	8.29%	28.54%	36.83%	63.17%	0.71
差异主成分	5.37%	23.84%	29.21%	70.79%	0.75
基于主成分的 ICA	15.29%	0.09%	24.38%	75.62%	0.87
基于多波段的 ICA	10.52%	7.30%	17.82%	82.18%	0.90

从实验结果上看，主成分差异法的变化检测结果最差，基于多波段的独立成分分析法的效果最好。其 Kappa 系数达到 0.90。

第七章 结 论

7.1 结论

对于多时相多光谱遥感图像, 是通过分析图像间的差异来实现变化信息检测。由于波段图像间存在着大量相互关联的信息, 使得对原始遥感图像的变化检测算法实现比较困难, 因此将原始数据经过变换以消除图像间的关联信息是实现变化检测的一种有效途径。

在遥感图像中, 每幅图像都是由多种地物混合组成, 如果各种地物的光谱特性都符合高斯分布, 则可以通过使用混合高斯模型模拟遥感图像。混合高斯模型在图像处理和分析中已经被广泛地应用, 也取得了比较理想的效果。对于多时相遥感图像, 各种地物的光谱信息在多时相遥感图像上的统计特性并不完全符合高斯分布。这样基于二阶统计特性的 PCA 处理方法就难以有效地实现多时相遥感图像分析。独立成分分析作为一种处理高阶统计的数据分析方法, 能够去除波段图像之间的相关性, 获得的波段图像是相互独立的, 本文根据遥感图像多波段多光谱和信息量大的特点和独立成分消除图像之间的相关信息的特性, 采用两种独立成分变换法对多时相遥感图像的变化检测进行研究。本文主要研究结论:

(1) 本文根据影响变化检测的因素, 对遥感图像进行预处理: 几何校正和相对辐射校正, 几何校正误差控制在 0.5 个像元内。相对辐射校正采用直方图匹配和伪不变特征法的相对辐射校正, 通过对校正结果的比较, 伪不变特征法的相对辐射校正效果较好。遥感图像的预处理消除像素的分辨率和大气条件对变化检测的影响。

(2) 在图像处理领域中, 由于图像获取, 传输过程中的种种原因导致了图像的混叠, 为了获得原始的图像, 往往需要对这些混合的图像进行分离。本文实验表明, 独立成分可以有效地进行混合图像分离。本文用六种 ICA 算法对自然图像和 TM 遥感图像做分离实验, 在自然图像分离实验中, Non-parametric ICA 算法分离效果较好, 但其运行时间较长; 其次是 Efficient ICA 算法, 其运行时间只有 0.5717s。在 TM 遥感图像中, 六种算法都能分离出植被与耕地的信息, Efficient ICA、EGLD_ICA、FastICA、Non-parametric ICA、Pearson-ICA 五种算法都能分离出水体的信息, 除了 JADE 算法外, 其他算法在一定程度上能把建设用地的信息分离出来。这说明独立成分分析法在遥感图像的处理中有很大的应用前景。

(3) 独立成分分析法处理遥感图像的影响因素有: 一是遥感影像波段数目; 二是遥感图像的大小; 三是遥感图像中的噪声。遥感影像波段数目和图像大小主要是影响 ICA 程序的运行时间, 波段数目越多、影像越大, ICA 程序运行时间就越长。尤其对 Non-parametric ICA 算法来, 其运行时间长达 2 个小时, 甚至十几个小时以上, 而 EGLD_ICA 算法即便对于 512×512 大小的遥感图像也很难收敛。遥感图像中的噪声主要影响分离效果, 本实验中, 噪声影响植被分量和水体分量的分离效果, 消除噪声后, 遥感图像的植被和水体分量的分离效果较好。

(4) 本文根据独立成分的特性和遥感影像的光谱特征, 采用基于主成分和多波段的独立成分分析两种方法应用于遥感变化的检测实验方法, 同时将实验结果与应用广泛的主成

分差异和差异主成分两种方法进行比较,实验结果表明,两种独立成分分析的方法的检测精度和 Kappa 系数都比主成分分析的两种方法高。而基于多波段的独立成分变换方法检测精度和 Kappa 系数最大。

7.2 不足之处

(1) 本文使用的 ICA 模型都是无噪模型,对于有噪声的图像,仅仅局限在图像预处理步骤的消除噪声的过程中。本文在自然图像的分离实验中实际上是就 ICA 简单去噪模型的一种,即实验图像与噪声图像利用混合矩阵进行线性混合,经过独立成分变换后,最后将图像与噪声分离。本人也对遥感图像做同样的实验,但是效果不是很好,希望在以后学习中找到原因。

(2) 阈值的选取。本文采取二维 Otsu 阈值分割算法,阈值是自动选取的,针对不同的图像,使用不同的阈值会得到不同的结果,因此如何选择合适的阈值选取方法,仍待进一步研究。

(3) 在内存方面,由于遥感图像数据数量较大,ICA 程序运行起来比较困难,如果遥感数据太大造成 Matlab 软件运行不起来,所以在要在节约内存方面解决这个问题。

(4) 由于遥感数据源有限,文中的实验还不够充分,不能通过大量的实验说明本文研究的方法是否具有普遍性,希望在以后的学习工作中尽量多方寻找各种数据,通过大量的实验来验证 ICA 算法在遥感图像处理上的应用范围。

参考文献

- [1] 戴昌达,姜小光,唐伶俐.遥感图像应用处理与分析[M].北京:清华大学出版社,2004.
- [2] 钟家强,王润生.基于独立成分分析的多时相遥感图像变化检测[J].电子与信息学报.2006,28(6): 994~、998.
- [3] 高建新.基于遥感影像的变化检测研究[J].测绘科技情报.2005,(2):1~4.
- [4] Singh A.Digital change detection techniques using remotely sensed data[J].Int J.Remote Sensing,1989,10(6):989~1003.
- [5] Jensen J R.Introductory Digital Image Processing:A Remote Sensing Perspective[M].New Jersey,Prentice Hall,1996.
- [6] Bruzzone L,Prieto D FAutomatic analysis of the difference image for unsupervised change detection[J].IEEE Trans.on Geosci.Remote Sensing,2000,38(3):1171~1182.
- [7] Herault,Ans B.Circuits neuronaux a synapses modifiables:decodage de messages composites par apprentissage non supervise.C-R.de l'Academie des Sciences,1984,299(III-13):525~528.
- [8] Herault J,Jutten C,Ans B.Detection de grandeurs primitives dans un message composite par une architecture de calcul neuromimetique en apprentissage non supervise.In:Actes du Xeme colloque GRETSI,1985,1017~1022.
- [9] Ans B,Herault J,Jutten C.Adaptive neural architectures:detection of primitives.In:Proceeding of Cogitiva,1985,593~597.
- [10] Herault J,Jutten C.Space or time adaptive signal processing by neural network models[J].In:AIP Conference Proceedings 151 on Neural Networks for Computing,1986,206~211.
- [11] Comon P.Independent component analysis-a new concept?[J].Signal Processing, 1994, 36:287~314.
- [12] Bell A,Sejnowski T.An information-maximization approach to blind separation and blind,deconvolution[J].Neural Computation,1995,7(6):1129~1159.
- [13] Bell A,Sejnowski T J.An on-line information maximization algorithm that performs blind separation[J].Advances in Neural Information Processing Systems,1995,7:467~474.
- [14] Amari S,Cichocki A,Yang H.A new learning algorithm for blind signal separation[J].Advances in Neural Information Processing Systems,1996,8:757~763.
- [15] Amari S.Neural learning in structured parameter spaces-natural Riemannian gradient[J].Advances in Neural Information Processing Systems,2000,9:127~133.
- [16] Cardoso J F,Laheld B H.Equivariant adaptive source separation[J].IEEE Transactions on Signal Processing,1996,44(12):3017~3030.
- [17] Cardoso J F.Blind Signal Processing:Statistical Principle[J].Proceedings of IEEE,1998,86(10):2009~2025.
- [18] Pearlmutter B,Parra L.A context-sensitive generalization of ICA[C].In:International Conference on Neural Information Processing(ICONIP'96),1996:151~157.
- [19] Pearlmutter B,Parra L.Maximum likelihood blind source separation:a context-sensitive generalization of

- ICA[J].Advances in Neural Information Processing Systems,1997,9:613~619.
- [20] Cardoso J F.Informax and maximum likelihood for blind separation[J].IEEE Signal Processing Letters,1997, 4(4):112~114.
- [21] Girolami M.An alternative perspective on adaptive independent component analysis algorithms[J].Neural Computation,1998,10:2103~2114.
- [22] Lee T W,Girolami M,Sejnowski T.Independent component analysis using an extended infomax algorithm for mixed subgaussian and supergaussian sources[J]. Neural Computation,1999,11(2):417~441.
- [23] Hyvarinen A,Oja E.A fast fixed-point algorithm for independent component analysis[J].Neural Computation,1997,9(7):1483~1492.
- [24] Hyvarinen A,Fast and robust fixed-point algorithm for independent component analysis[J].IEEE Transactions on Neural Networks,1999,10(3):626~634.
- [25] Hyvarinen A,Oja E.Independent component analysis:algorithms and applications[J].Neural Networks, 2000,13:411~430.
- [26] 周宗潭,董国华,徐昕,胡德文等译.独立成分分析[M].北京:电子工业出版社,2007.
- [27] Lee T W,Girolami M,Bell A,Sejnowski T J.A unifying information-theoretic frame-work for independent component analysis[J].Computers and Mathematics with Applications,2000,31(11):1~21.
- [28] Tong L,Liu R W,Soon V,Huang Y F.Indeterminacy and identifiability of blind identification[J].IEEE Transactions on Circuits and Systems,1991,38:499~509.
- [29] Cardoso J F,Souloumiac A.Blind beamforming for non Gaussian signals[J].IEEE Prococessing-F,1993, 140(6):362~370.
- [30] Cichocki A,Moszczynski L.A new learning algorithm for blind separation of sources[J].Electronics Letters, 1992,28(21):1986~1987.
- [31] Cichocki A,Unbehauen R,Rummert E.Robust learning algorithm for blind separation of signals[J]. Electronics Letters,1994, 30(17):1386~1387.
- [32] Cichocki A,Unbehauen R.Robust neural networks with on-line learning for blind identification and blind separation of sources[J].IEEE Transactions on Circuits and Systems,1996,43(11):894~906.
- [33] Oja E.Principal components,minor components,and linear neural networks[J].Neural Networks,1993,6: 627~648.
- [34] Chen T P,Hua Y,Yan W.Global convergence of Oja's subspace algorithm for Principle component extraction[J].IEEE Transactionson Neural Networks,1998,9(1):58~67.
- [35] Girolami M,Fyfe C.An extended exploratory Projection pursuit network with linear and nonlinear antihebbian lateral connections applied to the cocktail party problem[J].Neural Networks,1997,10(9): 1607~1618.
- [36] 胡波,凌燮亭.Hebbian 无导师学习原理的盲均衡:(I)最小相位通道[J].通信学报,1994,15(5):17~24.
- [37] 凌燮亭.延时狭带信号的自学习盲分离[J].电子学报,1995,23(1):28~33.
- [38] 张贤达.时间序列分析——高阶统计量方法[M].北京:清华大学出版社,1996.
- [39] 张贤达,朱孝龙,保铮.基于分阶段学习的盲信号分离[J].中国科学,E 辑,2002,32(5):693~703.
- [40] 汪军,何振亚.基于高阶谱的信号盲分离[J].东南大学学报,1996,26(5):75~78.

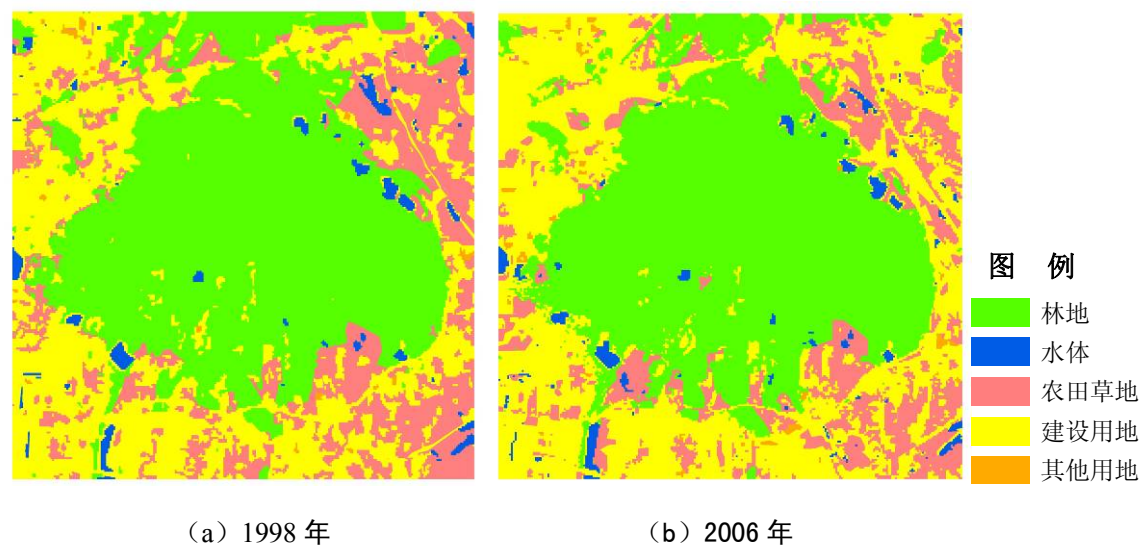
- [41] 何振亚,杨绿溪,鲁子奕.非线性 Informax 自组织算法的盲源分离机理[J].数据采集与处理,1998,13(4):303~305.
- [42] 刘据,梅良模,何振亚.一种盲信号分离的信息理论方法[J].山东大学学报(自然科学版), 1998,33(4): 398~403.
- [43] 刘据,顾明亮,何振亚.一种新的瞬时混迭信号盲分离的自适应方法[J].电路与系统学报,1998,3(4): 66~71.
- [44] 史维祥,冯大政.有效的自适应波达方向盲估计算法[J].电子学报,1999,27(a):1~4.
- [45] 冯大政,保铮,张贤达.信号盲分离问题多阶段分解算法[J].自然科学进展,2002,12(a):324~328.
- [46] 虞晓,胡光锐.基于高斯混合密度函数估计的语音分离[J].上海交通大学学报,2000,34(2):177~180.
- [47] 吴小培,詹长安,周荷琴,冯焕清.采用独立分量分析方法消除信号中的工频干扰[J].中国科学技术大学学报,2000,30(6):671~676.
- [48] 李全政,高小榕,欧阳靖.胸阻抗信号中的呼吸波的去除[J].清华大学学报(自然科学版),2000,40(9): 13~16.
- [49] 洪波,唐庆玉,杨福生,潘映辐,陈葵,铁艳梅.ICA 在视觉诱发电位的少次提取与波形分析中的应用[J].中国生物医学工程学报,2000,19(3):334~341.
- [50] Hyvarine.A.Complexity pursuit:separating interesting components from time-series[J].Neural Computation,2001,13(4):883~898.
- [51] Cichocki.A,Karhunen.J,Kasprzak.W.Neural Networks for blind separation with unknown number of sources[J].Neurocomputing,1999,24:55~93.
- [52] 张发启,张斌,张喜斌.盲信号处理及应用[M].西安:西安电子科技大学出版社,2006.
- [53] Cover T M,Thomas J A.Elements of Information Theory[M]. New York,Wiley,1991.
- [54] Cardoso J F,Soloumiac A.Blind beamforming for non-Gaussian signals[J].IEEE-Proceedings-F(S0956-375X).1993,140(46):362~370.
- [55] 丁丽霞,周斌,王人潮.遥感监测中 5 种相对辐射校正方法研究[J].浙江大学学报,2005,31(3):269~276.
- [56] 姜小光,王长耀,王成.成像光谱数据的光谱信息特点及最佳波段选择[J].干旱地理,2000, 21(3):214~220.
- [57] 刘建平,赵英时.高光谱遥感数据解译的最佳波段选择方法的研究[J].中国科学院研究生院学报,1999, 169(2):153~161.
- [58] 陈超,江涛,刘祥磊.基于缨帽变换的遥感图像融合方法研究[J].测绘科学,2009.
- [59] Zbynek K,Petr T,Erkki O.Efficient variant of algorithmFastICA for independent component analysis attaining the Cramér-Rao LowerBound[J].IEEE Trans. on Neural Networks, 2006,17(5).
- [60] Juha K.Adaptive methods for score function modeling in blind source separation[D].Espoo: Helsinki University of Technology,2002.
- [61] Ella B,Aapo H.A fast fixed-point algorithm for independent component analysis of complex valued signals[J].International Journal of Neural Systems,2000,10(1).
- [62] 王晓伟,石林锁,成浩.基于独立分量分析的图像特征提取[J].电子测量与仪器学报,2007,增刊:296、~300.
- [63] Riccardo B,Hong P,Vwani P.Roychowdhury.Non-parametric ICA:Proceedings of the Third International

Conference on Independent Component Analysis and Blind Signal Separation[C].San Diego: LEE T W,JUNG T W, MAKEIG S,*et al*,2001:13~18.

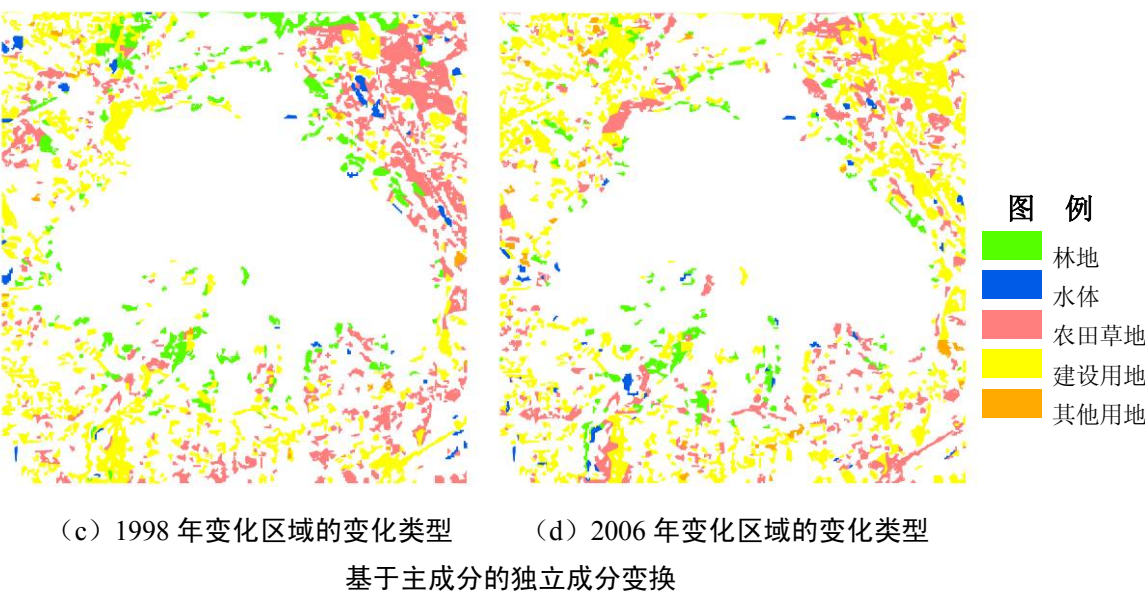
- [64] Juha K,Jan E,Visa K.Pearson system based method for blind separation: Proceedings of Second International Workshop on Independent Component Analysis and Blind Signal Separation[C].Helsinki: PAJUNEN P,KARHUNEN J,2000:585~590.
- [65] HongLi,Yunlian Sun.The study and test of ICA algorithms[C].IEEE,2005.
- [66] 陈述彭,同庆禧,郭华东.遥感信息机理研究[M].北京:科学出版社.1998.
- [67] 李月臣,杨华,刘春霞.土地覆盖变化遥感检测方法[J].水土保持研究,2006,2(1):210~213.
- [68] Fung T,Siu W.Environmental quality and its change,an analysis using NDVI[J]. INT.J.Remote Sensing, 2000,21(5):339~355.
- [69] 贾凌.基于 TM 的海南省土地利用/覆盖动态变化的遥感监测和分析[J].遥感信息, 2003,(1):22~26.
- [70] Hazel,G.G.,2001,Object-level change detection in spectral imagery.Geoscience and Remote Sensing,IEEE Transactions on,Volume:39Issue:3,March 2001,pp.553~561.
- [71] 刘鹰,张继贤,林宗坚.土地利用动态遥感监测中变化信息提取方法的研究[J].遥感信息,1999(4): 21~24.
- [72] 黎夏,叶嘉安.利用主成分分析改善土地利用变化的遥感监测精度[J].遥感学报,1997(4):283~289.
- [73] Sahoo P K.A survey of threshold technique.Computer Vision Graphic[J],Image Process,1988,41(2): 233~260.
- [74] 刘建庄,栗文清.灰度图像的二维自动阈值分割法[J].自动化学报,1993,19(1):101~105.


附图

附图一：研究区域目视解译图




附图二：两期图像上的对应的变化区域的地域类型图像






(e) 1998 年变化区域的变化类型




(f) 2006 年变化区域的变化类型

基于 4、5、7 三波段的独立成分变换

图 例




(g) 1998 年变化区域的变化类型





(h) 2006 年变化区域的变化类型

差异主成分法

图 例





(i) 1998 年变化区域的变化类型

(j) 2006 年变化区域的变化类型

主成分差异法

学 号:3090623 作 者:孙 青 指导教师:彭世揆 教 授

专 业:森林经理学 研究方向:遥感与地理信息系统

论文题目:基于独立成分分析的遥感影像变化检测

详细摘要

多时相遥感图像变化检测是通过分析同一地区不同时间得到的遥感图像,定量分析和确定地物变化特征和过程的技术,用于资源 and 环境监测、自然灾害评估以及战场态势分析等。随着遥感技术的发展,变化检测已经成为当前遥感图像应用研究的一个重要方向。

PCA 是基于二阶统计的方法,只有在信号的统计分布符合高斯情况时,才能完全消除信号间的相关信息,而对于非高斯信号则只能去除信号间的二阶相关信息。但在多时相遥感图像中,各种地物的光谱特性并不都满足高斯分布,因此经过 PCA 变换的各成分图像间仍然存在高阶相关信息,而这些相关信息会影响到变化信息的检测。独立成分分析(ICA)作为近年出现的盲源分离技术,能够有效地消除多源信号间的二阶和高阶相关,经其变换的各分量之间相互独立。

独立分量分析在图像分离中的应用是最为成功的应用。独立分量分析算法的初衷就是对混合了相互独立的信号的观测信号进行分离的,并有着很好的效果。图像从信号角度看可以认为是二维信号,并且二维图像可以重新排列成为一维的信号,因此应用独立分量分析分离图像也是很自然的了。本文选择三幅自然图像,并将其与一幅随机产生的噪声图像混合,经过本文介绍的六种 ICA 算法进行图像分离,Non-parametric ICA 分离效果最好,其次是 Efficient ICA。

应用独立成分分析算法对多光谱遥感图像进行分离,当多光谱遥感图像的谱段足够多,多到和地物的类型相等时,理论上认为分离出来的结果谱段图像正好对应于每种地物的光谱反映。因此,只要找到分离结果图像和地物之间的对应关系,结果图像就直接是该地物的一种分类结果,图像上反映的信息就是该地物或非该地物了。但是由于地物的多样性或卫星的技术不可能会有和地物对应多的传感器,也就不可能有如此多的谱段与地物一一对应,所以独立分量分析算法只能使得分离得到的每个结果谱段里尽可能地集中某种地物的信息,本文将六种 ICA 算法应用到 TM 图像的分离试验中,选择 TM 图像的 1、2、3、4、5、7 六个波段进行分离试验,六种算法都能分离出植被、耕地和水体的信息,除了 JADE 算法外,其他算法在一定程度上能把建设用地的信息分离出来。而 Non-parametric ICA 分离效果最好,其次是 Efficient ICA。

本文根据独立成分分析和不同时期遥感图像的特点,运用独立成分分析模型实现遥感影像变化检测。由于前、后时相的原始遥感影像包含多个波段,所以本文采用两种独立成分分析的方法对多时相遥感图像进行变化检测。

一是基于主成分分析的独立成分变换,此方法是将前后两时相的遥感图像进行主成分变换,使多波段图像信息集中到前两个主成分上,两时相主成分包含的信息量都达到了 90%

以上。然后对两时相主成分进行独立成分分析，实现变化检测。

二是基于多波段的独立成分变换。此方法是通过对两时相遥感图像的波段光谱特征、信息熵、相关系数等进行分析，选出最优波段组合，通过实验研究，本文选择波段 4、5、7 三波段作为实验波段组合，然后对两时相影像的三个波段组合进行独立成分变换，得到变化区域信息。

最后将本文提出的方法用于实验，并与常用的 PCA 方法进行了比较，实验结果显示第二种独立成分分析方法较好。

关键词：遥感图像；变化检测；独立成分分

Remote Sensing Images Change Detection Based on ICA

Abstract

Through change detection between multi-temporal remote sensing images of the same region, one can determine the change characters and process quantificationally for the remote sensing images obtained from different time. It is used for resources and environment monitoring, evaluation and natural disasters of battlefield analysis, etc. With development of remote sensing, change detection has become an important research direction of remote sensing images's application.

PCA is a method based on second-order statistics, only the statistics of the signal distribution, subject to the Gaussian case, to completely eliminate the signal information, and for non-Gaussian signal can only remove the signal between the second-order information. But in the multi-temporal remote sensing image, the spectral characteristics of various surface features do not satisfy the Gaussian distribution, so after PCA transform, the components of the image still exist between high order related information, and the related information will affect change information detection. Independence component Analysis (ICA) is a blind source separate technique appeared in recent years, It can reduce second and high-order dependences in observed data, and the independent components are statistically as independent as possible.

Independent Component Analysis in image separation is the most successful applications. The original intention of independent component analysis algorithm separate mixed independent signal observation signal, and it has a good effect. From the perspective of signals, the image can be thought of as a two-dimensional signal, and a 2D image can be rearranged into a one-dimensional signal. Therefore the application of independent component analysis to separate image also is very natural. This paper selected three natural images, and mixed it with a randomly generated noise image. This paper separate image with six kinds of ICA algorithm. Non-parametric ICA is the best algorithm, The second is Efficient ICA.

Independent component analysis algorithm separate the multi-spectral remote sensing image. When the spectral bands of multispectral remote sensing image is more than enough, equal with the surface features, theoretically, separated spectral image is correspond to each object's spectral reflection. So, as long as the result of the separation of images and the corresponding relations between the features, the result is a classification results of the features, information reflected in the image is the surface features or not. But because of the diversity of objects or satellite technology may not be and object corresponding to a plurality of sensor, there can be no so many spectrum segment and features the one-to-one. So independent component analysis algorithm can only makes the separation of the spectrum to get each segment on the ground as far as possible some information. This paper used six ICA algorithm in the TM images of separation test, selected the TM images of 1, 2, 3, 4, 5, 7, six bands for separation test. The six algorithms can separate the

vegetation, and cultivated land and water information. In addition to the JADE algorithm, other algorithms can separate information of construction land to a certain extent. And Non-parametric ICA is the best algorithm, the second is Efficient ICA.

In this paper, according to independent component analysis and different period of remote sensing image characteristics, use independent component analysis model realize remote sensing image change detection. Because the before and after phase's remote sensing images contains many wave bands, therefore this paper achieves the change detection based on multi-temporal remote sensing image by using two kinds of independent component analysis.

First, the independent component analysis based on principal component transform. This method is to carry on the principal components transformation to Around two phase remote sensing images, make the multi-band image information into the first two principal components, then carry on the independent component analysis to two phase principal components, to achieve change detection.

Second, the independent component analysis based on multi-wave band image. This method is to select the most superior wave band combination through the analysis band spectral features, information entropy, correlation coefficient of the two phase remote sensing image. After the experimental study, select the band 4, 5, 7 as an experimental band combination, and then use the three band combination of the phase two images do independent component transformation, to get change information area.

Finally, use these two methods in the experiment, and compared with PCA, the results show that the second independent component analysis method is better.

Keywords: Remote sensing image; change detection; independent component analysis